动态规划

动态规划是一类用于在**已知环境为马尔可夫决策过程（MDP）的完整模型**下，计算最优策略的算法。**前提条件**是环境是**有限 MDP**（状态、动作、奖励集合有限）且转移概率 $p(s', r \mid s, a)$ 和奖励函数完全已知。其**核心思想**为利用**价值函数**来组织和结构化对良好策略的搜索。但其也存在需要环境的**完美模型**和计算开销大的缺陷。

> Important
>
> **最优状态价值函数** $v_*(s)$
>
> 满足贝尔曼最优方程：
>
> $$v_*(s) = \max_a \sum_{s',r} p(s',r|s,a) \left[r + \gamma v_*(s')\right] \tag{4.1}$$
>
> 最优状态价值函数 $v_*(s)$ 表示在状态 s 下遵循最优策略所能获得的期望回报。该方程表明：状态 s 的最优价值等于**所有可能动作中期望回报的最大值**，其中每个动作的期望回报是通过对所有可能的下一个状态 s' 和奖励 r 按环境动态特性 $p(s',r|s,a)$ 进行加权平均计算得到的，每个加权项包括即时奖励 r 加上折扣因子 γ 乘以后续状态 s' 的最优价值 $v_*(s')$。
>
> **最优动作价值函数** $q_*(s,a)$
>
> 满足贝尔曼最优方程：
>
> $$q_*(s,a) = \sum_{s',r} p(s',r|s,a) \left[r + \gamma \max_{a'} q_*(s',a')\right] \tag{4.2}$$
>
> $q_*(s,a)$ 就是计算在状态 s 执行动作 a 后，对所有可能结果的期望回报，其中每个可能结果的回报包括即时奖励和后续状态的最优动作价值。它描述了在状态 s 选择特定动作 a 的长期价值，假设之后的所有动作都遵循最优策略。
>
> 一旦求得 v_* 或 q_*，即可直接导出最优策略：
>
> $$\pi_*(a|s) = \begin{cases} 1, & \text{if } a = \arg\max_a q_*(s,a) \\ 0, & \text{otherwise} \end{cases}$$

旦我们找到了最优价值函数 v_* 或 q_*，就可以很容易地获得最优策略。DP将贝尔曼方程转化为**迭代更新规则**；通过不断"改进"价值函数近似值，逐步逼近真实价值函数。

策略评估

策略评估即计算任意给定策略 π 下的状态价值函数 $v_\pi(s)$。

> Important
>
> 定义回顾
>
> $$v_\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s] = \mathbb{E}_\pi[R_{t+1} + \gamma v_\pi(S_{t+1}) \mid S_t = s] \tag{4.3}$$
>
> $$v_\pi(s) = \sum_a \pi(a|s) \sum_{s',r} p(s',r|s,a) \left[r + \gamma v_\pi(s')\right] \tag{4.4}$$
>
> 状态价值函数 $v_\pi(s)$定义为：在策略 π 下，从状态 S 开始，智能体遵循该策略行动时，未来所有折扣奖励的期望累积回报。其中 $\pi(a|s)$ 表示在状态S下根据策略 π 采取动作 a 的概率，下标 π 表示期望是基于遵循策略 π 的条件。只要$\gamma < 1$或者任何状态在π下都能 保证最后终止, 那么 v_π **唯一存在**。
>
> 在环境的动态特性完全已知时，这是一个包含 $|\mathcal{S}|$ 个未知数的线性方程组；可以直接求解，但更常用的是**迭代法**。

迭代策略评估

计算策略 π 下的状态价值函数 $v_\pi(s)$，通过迭代逼近贝尔曼期望方程：

$$\begin{aligned} v_{k+1}(s) &\doteq \mathbb{E}_\pi\left[R_{t+1}+\gamma v_k(S_{t+1}) \mid S_t=s\right] \\ &= \sum_{a\in\mathcal{A}(s)} \pi(a|s) \sum_{s'\in\mathcal{S}^+} \sum_{r\in\mathcal{R}} p(s',r \mid s,a)\left[r+\gamma v_k(s')\right], \quad \forall s\in\mathcal{S} \end{aligned} \tag{4.5}$$

该公式描述了策略评估中状态价值函数的迭代更新过程：对于任意状态 s，新估计值 $v_{k+1}(s)$ 被定义为在策略 π 下，从 s 执行单步动作后，所有可能转移路径的期望回报。

收敛条件：

$$\max_{s\in\mathcal{S}} |v_{k+1}(s) - v_k(s)| < \theta$$

其中 $\theta > 0$ 是预设的小阈值。初始值 $v_0(s)$ 可任意设定，但终止状态必须为0。在每一次迭代中，计算**所有状态** s 的最新状态价值函数 $v_{k+1}(s)$ 与上一次迭代的状态价值函数 $v_k(s)$ 之间的绝对差值，然后取这些差值中的**最大值**。如果这个最大差值小于θ，我们就认为状态价值函数已经“足够稳定”，即算法**收敛**了，可以停止迭代。

期望更新

在动态规划中，**期望更新**指根据**环境的完整模型**（即已知转移概率 $p(s',r \mid s,a)$ 和奖励函数），**精确计算当前状态价值的期望值**，并以此来更新该状态的价值估计。**期望更新是迭代更新的原子操作**——迭代更新通过**反复执行期望更新**（即利用环境模型精确计算单步期望价值）逐步逼近真实价值函数；而期望更新必须**嵌入迭代框架**才能实现全局收敛。

具体到当前案例（如策略评估）：

- **单步层面**：每次迭代中，对每个状态 s 执行**期望更新**（公式 $v_{k+1}(s)=\sum_a \pi(a|s)\sum_{s',r} p(s',r|s,a)[r+\gamma v_k(s')]$），**精确计算**该状态的新价值。
- **整体过程**：**迭代更新**将上述操作循环应用于所有状态，直至满足收敛条件（如 $\max_s |v_{k+1}(s)-v_k(s)|<\theta$），最终使 v_k 收敛到 v_π。

本质：期望更新提供**数学精确性**（依赖环境模型），迭代更新提供**收敛性**（通过重复应用）。二者缺一不可：无期望更新则迭代失去理论基础，无迭代则期望更新无法收敛。

> **Caution**
>
> **为什么在动态规划中，期望更新（expected update）可以让价值函数离真实值更近？**
>
> 状态价值函数 $v_\pi(s)$ 的真实值，由贝尔曼期望方程定义：
>
> $$v_\pi(s) = \mathbb{E}_\pi\left[R_{t+1}+\gamma v_\pi(S_{t+1}) \mid S_t=s\right]$$
>
> 也就是说，**真实价值函数是满足这个方程的唯一解**（在有限状态空间、$\gamma<1$ 的条件下）。
>
> 在策略评估（Policy Evaluation）中，我们迭代地做：
>
> $$v_{k+1}(s) \leftarrow \sum_a \pi(a|s) \sum_{s',r} p(s',r|s,a)\left[r+\gamma v_k(s')\right]$$
>
> 这其实就是**贝尔曼期望算子** $\mathcal{T}^\pi$ 的应用：
>
> $$v_{k+1} = \mathcal{T}^\pi v_k$$
>
> > 贝尔曼期望算子 $\mathcal{T}^\pi$ 是关于**上确界范数（sup-norm）** 的 γ-压缩映射：
>
> $$\|\mathcal{T}^\pi v - \mathcal{T}^\pi u\|_\infty \le \gamma \|v-u\|_\infty$$
>
> 其中 $0\le\gamma<1$。
>
> **这意味着**：每次应用 $\mathcal{T}^\pi$，任意两个价值函数之间的“最大误差”至少缩小 γ 倍。所以从任意初始 v_0 开始，序列 $v_0, v_1, v_2, \ldots$ 会**指数收敛**到真实 v_π。**期望更新 = 应用压缩映射 → 误差缩小 → 更接近真实值。**

迭代策略评估的实现有有两种方式，**双数组法**和**原地更新法**。

双数组法使用两个独立的价值函数数组：$v_{\text{old}}(s)$表示 $v_k(s)$，即上一轮的值；$v_{\text{new}}(s)$表示 $v_{k+1}(s)$，即本轮计算的新值。所有更新基于 v_{old}，确保同步性。

伪代码

$$
\begin{aligned}
&\textbf{Input: } \pi,\ \gamma,\ \theta > 0 \\
&\textbf{Initialize:} \\
&\quad \text{For all } s \in \mathcal{S}^+ : \\
&\qquad v_{\text{old}}(s) \leftarrow c_s \quad (\text{任意初始化，如 } c_s = 0) \\
&\qquad v_{\text{new}}(s) \leftarrow 0 \\
&\quad v_{\text{old}}(\text{terminal}) \leftarrow 0 \\
&\quad v_{\text{new}}(\text{terminal}) \leftarrow 0 \\
\\
&\textbf{Repeat:} \\
&\quad \delta \leftarrow 0 \\
&\quad \text{For each } s \in \mathcal{S} : \\
&\qquad v_{\text{new}}(s) \leftarrow \sum_{a \in \mathcal{A}(s)} \pi(a|s) \sum_{s' \in \mathcal{S}^+} \sum_{r \in \mathcal{R}} p(s', r|s, a) \left[r + \gamma \cdot v_{\text{old}}(s') \right] \\
&\quad \text{For each } s \in \mathcal{S} : \\
&\qquad \delta \leftarrow \max\left(\delta,\ \left| v_{\text{new}}(s) - v_{\text{old}}(s) \right|\right) \\
&\quad \text{For each } s \in \mathcal{S} : \\
&\qquad v_{\text{old}}(s) \leftarrow v_{\text{new}}(s) \\
&\textbf{Until } \delta < \theta \\
\\
&\textbf{Output: } V(s) = v_{\text{old}}(s) \approx v_\pi(s)
\end{aligned}
$$

所有 $v_{\text{new}}(s)$ 都基于 v_{old} 计算；需存储两个完整价值函数，**内存开销大**。虽然**收敛稳定**，但是速度较慢。

> **Note**
>
> 考虑一个确定性线性链式马尔可夫决策过程（MDP）：
>
> - 状态空间 $\mathcal{S} = \{s_1, s_2, \ldots, s_{100}\}$，其中 s_{100} 为终止状态
> - 状态转移：$s_i \rightarrow s_{i+1}$（对 $i = 1, 2, \ldots, 99$），s_{100} 无后续状态
> - 即时奖励：所有转移的奖励 $r = -1$
> - 策略 π：确定性策略，每个状态只有一个可行动作
> - 折扣因子：$\gamma = 1$
> - 理论上，状态价值函数应为 $v_\pi(s_i) = -(100 - i)$
>
> 详细过程分析
>
> 初始化阶段
>
> $$
> \begin{aligned}
> &\text{For all } s \in \mathcal{S}^+ : \\
> &\quad v_{\text{old}}(s) \leftarrow c_s \ (\text{如 } c_s = 0) \\
> &\quad v_{\text{new}}(s) \leftarrow 0 \\
> &v_{\text{old}}(\text{terminal}) \leftarrow 0 \\
> &v_{\text{new}}(\text{terminal}) \leftarrow 0
> \end{aligned}
> $$
>
> 状态$v_{\text{old}}(s)$、$v_{\text{new}}(s)$ 被初始化为 $0
>
> 第一轮迭代过程
>
> 重置变化量
>
> $$\delta \leftarrow 0$$
>
> 准备记录本轮迭代中的最大变化

计算新价值

$$\text{For each } s \in \mathcal{S}:\\ v_{\text{new}}(s) \leftarrow \sum_{a \in \mathcal{A}(s)} \pi(a|s) \sum_{s' \in \mathcal{S}^+} \sum_{r \in \mathcal{R}} p(s', r|s, a) \left[r + \gamma \cdot v_{\text{old}}(s')\right]$$

- **关键点**：计算 $v_{\text{new}}(s)$ 时**严格使用** $v_{\text{old}}(s')$
- 对于 s99:
  - $v_{\text{new}}(s99) = -1 + \gamma \cdot v_{\text{old}}(s100) = -1 + 1 \cdot 0 = -1$
  - 这里使用的是**初始化后的** $v_{\text{old}}(s100) = 0$
- 对于 s98 及之前的状态:
  - $v_{\text{new}}(s98) = -1 + \gamma \cdot v_{\text{old}}(s99) = -1 + 1 \cdot 0 = 0$（因为 $v_{\text{old}}(s99)$ 仍是初始化值 0）
  - $v_{\text{new}}(s97) = -1 + \gamma \cdot v_{\text{old}}(s98) = -1 + 1 \cdot 0 = 0$
  - 所有其他状态的 v_{new} 仍为 0
- **第一轮结束后**:
  - $v_{\text{new}}(s99) = -1$（因为 $v_{\text{old}}(s100) = 0$ 已知）
  - $v_{\text{new}}(s98) = 0$（因为 $v_{\text{old}}(s99)$ 仍是 0）
  - $v_{\text{new}}(s97) = 0$
  - ...所有其他状态的 v_{new} 仍为 0

步骤 3: 计算变化量

$$\text{For each } s \in \mathcal{S}:\\ \delta \leftarrow \max\left(\delta, |v_{\text{new}}(s) - v_{\text{old}}(s)|\right)$$

- 对于 s99: $|v_{\text{new}}(s99) - v_{\text{old}}(s99)| = |-1 - 0| = 1$
- 其他状态变化为 0
- 所以 $\delta = 1$

步骤 4: 同步更新数组

$$\text{For each } s \in \mathcal{S}:\\ v_{\text{old}}(s) \leftarrow v_{\text{new}}(s)$$

- **此时**，$v_{\text{old}}(s99)$ 才被更新为 -1
- $v_{\text{old}}(s98)$ 仍为 0（因为 $v_{\text{new}}(s98)$ 为 0）

在第二轮迭代中：

- $v_{\text{old}}(s99) = -1$（第一轮已更新）
- $v_{\text{old}}(s100) = 0$（终止状态）
- 计算 $v_{\text{new}}(s98) = -1 + v_{\text{old}}(s99) = -1 + (-1) = -2$
- 其他状态仍无法正确计算

关键结论

1. **第一轮迭代中**:

- $v_{\text{old}}(s99)$ **保持为初始值** 0（直到本轮迭代结束）
- $v_{\text{new}}(s99)$ **被计算为** -1
- 价值信息**只传播了一步**：从 s100 到 s99

2. **双数组法的核心机制**:

- 所有 v_{new} 的计算**严格基于上一轮的** v_{old}
- 一轮迭代内，**新计算的值不会影响同轮其他状态的计算**

- 价值信息**每轮只能向前传播一步**

3. **"从后往前"的真正含义**:

- 这不是指遍历顺序，而是指**价值信息的传播方向**
- 从已知的终止状态（s100）开始
- 第1轮：影响 s99
- 第2轮：影响 s98
- ...
- 第99轮：影响 s1

双数组法中，第一轮结束前，s99 的新值只存在于 $v_{\text{new}}(s99)$ 中，$v_{\text{old}}(s99)$ 仍然是初始值。只有当第一轮迭代完全结束后，通过"$v_{\text{old}}(s) \leftarrow v_{\text{new}}(s)$"操作，$v_{\text{old}}(s99)$ 才会更新为 -1，为第二轮迭代中计算 s98 的正确值奠定基础。

> Caution

为什么要使用负奖励?

在强化学习中，**奖励的设计决定了智能体的行为目标。**

在上面例子设定下，**负奖励 -1 的含义是：每走一步都要付出"时间成本"或"能量代价"。这模拟的是"最短路径"问题** —— 我们希望智能体以**最少步数**从起点到达终点。

奖励设计	含义	智能体行为倾向
$r=-1$ 每步	走得越久，总奖励越低	尽快到达终点
$r=0$ 每步	中立，无时间成本	可以无限拖延（可能不收敛）
$r=+1$ 每步	走得越久，得分越高	故意拖延，永远不到达终点。

所以负奖励 -1 的作用是鼓励"快速完成任务"。智能体知道**每多走一步就多损失 1 点奖励**，所以它会倾向于选择能**最快到达终点**的路径，在这个确定性链中，只有一条路径，所以策略唯一，但价值函数反映了"剩余步数"的代价。

> Caution

在当前的价值迭代过程中，**什么时候循环结束?**

当所有状态的价值变化量（δ）小于某个小阈值（θ）时，算法收敛，停止迭代。

由上有**需要 99 轮迭代，才能让 s_1 的价值收敛到** -99。在第 99 轮之后，所有状态都已经正确，$\delta=0$，无论设置多小的θ，都满足$\max_s |v_{\text{new}}(s)-v_{\text{old}}(s)|<\theta$，循环结束。

> Caution

错误认识：**如果每步奖励是 -1，那从 s_1 开始要走 99 步才能到 s_{100}，所以 $v(s_{99})$ 不应该是 -99 吗?**

"$v(s_{99})$ 应该是 -99" —— 这是把 **从 s_1 到 s_{100} 的总代价** 错误地套用到了 s_{99} 上。

但价值函数 $v_\pi(s_i)$ 的定义是：

> **从状态 s_i 出发，遵循策略 π 所能获得的未来回报（return）的期望值。**

在这个 MDP 中：

- 从 s_{99} 出发，只能走一步：$s_{99} \to s_{100}$，奖励为 -1
- 到达 s_{100} 后终止，不再有奖励
- 折扣因子 $\gamma=1$

所以总回报是：

$$v_\pi(s_{99}) = r = -1$$

- $v_\pi(s_{98}) = -1 + v_\pi(s_{99}) = -1 + (-1) = -2$
- $v_\pi(s_{97}) = -1 + v_\pi(s_{98}) = -1 + (-2) = -3$
- ...
- $v_\pi(s_i) = -(100 - i)$

而价值函数只关心**未来**，不关心过去。

> ⓘ **Note**
>
> 上面的式子仍然是基于期望更新去进行处理的：
>
> “期望更新”指的是：
>
> > 在更新 $v(s)$ 时，我们不是用某一次采样结果，而是**对所有可能的下一状态和奖励，按其发生概率加权平均** —— 即计算数学期望。
>
> 公式：
>
> $$v_{\text{new}}(s) \leftarrow \mathbb{E}_\pi \left[R_{t+1} + \gamma v_{\text{old}}(S_{t+1}) \mid S_t = s \right]$$
>
> 展开就是：
>
> $$v_{\text{new}}(s) = \sum_a \pi(a|s) \sum_{s',r} p(s', r|s, a) \left[r + \gamma v_{\text{old}}(s') \right]$$
>
> 因为本题的 MDP 是**完全确定性**的：
>
> - 每个状态 s_i 只有一个动作（$\pi(a|s) = 1$）
> - 每个动作导致**唯一**的下一状态 s_{i+1}（$p(s_{i+1}, -1|s_i, a) = 1$）
> - 没有其他分支、没有随机性
>
> 所以在计算期望时：
>
> $$\sum_a \pi(a|s) \sum_{s',r} p(s', r|s, a)[\cdots] = 1 \cdot 1 \cdot [-1 + \gamma v_{\text{old}}(s_{i+1})]$$
>
> → 所以“期望”变成了“单一值”，**但数学上它仍然是期望，只是这个期望的支撑集（support）只有一个点。**
>
> > 对于 s99:
> > $v_{\text{new}}(s99) = -1 + \gamma \cdot v_{\text{old}}(s100)$
>
> 这实际上是：
>
> $$\begin{aligned} v_{\text{new}}(s_{99}) &= \sum_a \pi(a|s_{99}) \sum_{s',r} p(s', r|s_{99}, a) \left[r + \gamma v_{\text{old}}(s') \right] \\ &= 1 \cdot p(s_{100}, -1 \mid s_{99}, a) \cdot [-1 + \gamma v_{\text{old}}(s_{100})] \quad (\text{假设确定性转移且唯一动作}) \\ &= -1 + \gamma v_{\text{old}}(s_{100}) \end{aligned}$$
>
> **这个求和过程就是期望”** 只是因为概率质量集中在唯一一个 (s', r) 上，所以看起来像直接赋值。

原地更新法只使用一个价值函数数组 $V(s)$，在扫描状态时**立即用新值覆盖旧值**。更新时，右侧的 $V(s')$ 可能已是**本轮刚更新过的值**（若 s' 已被访问），从而加速信息传播。

伪代码

Input: $\pi,\ \gamma,\ \theta > 0$
Initialize:
  For all $s \in \mathcal{S}^+$:
    $V(s) \leftarrow c_s$ (任意初始化，如 0)
  $V(\text{terminal}) \leftarrow 0$

Repeat:
  $\delta \leftarrow 0$
  For each $s \in \mathcal{S}$ (in a fixed order) :
    $\text{old\_value} \leftarrow V(s)$
    $V(s) \leftarrow \sum_{a \in \mathcal{A}(s)} \pi(a|s) \sum_{s' \in \mathcal{S}^+} \sum_{r \in \mathcal{R}} p(s', r|s, a) \left[r + \gamma \cdot V(s')\right]$
    $\delta \leftarrow \max\left(\delta,\ |\text{old\_value} - V(s)|\right)$
Until $\delta < \theta$

Output: $V(s) \approx v_\pi(s)$

案例

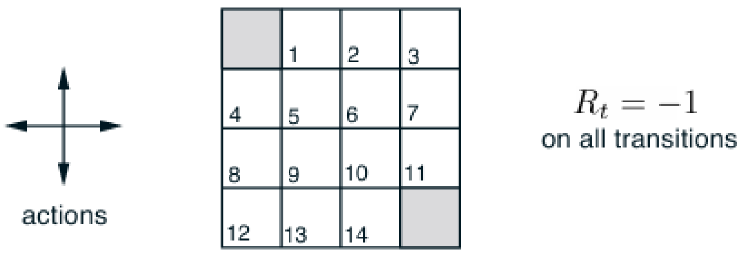

状态空间

- 非终止状态集合：$\mathcal{S} = \{1, 2, \ldots, 14\}$（共 14 个状态）
- 终止状态：图中阴影格子（即 (0,0) (3,3) 虽然图示两个格子，但实际为**同一个终止状态**）

动作空间

- 动作集合：$\mathcal{A} = \{\text{up}, \text{down}, \text{left}, \text{right}\}$
- **边界处理**：若动作导致移出网格，则**状态保持不变**（即"撞墙"留在原地）
  - 例如：
    - $p(6, -1 \mid 5, \text{right}) = 1 \rightarrow$ 从 5 向右走到 6
    - $p(7, -1 \mid 7, \text{right}) = 1 \rightarrow$ 从 7 向右撞墙，仍留在 7
    - $\forall r,\ p(10, r \mid 5, \text{right}) = 0 \rightarrow$ 5 向右不可能到 10

奖励函数

- 所有非终止转移的即时奖励：$r = -1$
- 到达终止状态后幕结束，无后续奖励
- 期望奖励函数：$r(s, a, s') = -1$ （对所有合法转移）

策略

- **等概率随机策略**：$\pi(a \mid s) = 0.25$，对所有 $a \in \mathcal{A}$
- 即：在每个状态，智能体以 25% 概率选择上、下、左、右

任务类型

- **分幕式（Episodic）任务**：存在明确终止状态

- **无折扣（$\gamma = 1$）**：未来奖励不打折，价值 = 负的期望步

练习

1. 计算 $q_\pi(11, \text{down})$

$$q_\pi(s,a) = \mathbb{E}_\pi\left[R_{t+1} + \gamma v_\pi(S_{t+1}) \mid S_t = s, A_t = a\right]$$

→ 由于转移是确定性的：

$$q_\pi(11, \text{down}) = r + \gamma \cdot v_\pi(\text{终止状态}) = -1 + 1 \cdot 0 = \boxed{-1}$$

因为该动作**直接进入终止状态**，无后续价值，仅获得即时奖励 -1。

2. 计算 $q_\pi(7, \text{down})$

$$q_\pi(7, \text{down}) = r + \gamma \cdot v_\pi(11) = -1 + v_\pi(11)$$

→ 需要求 $v_\pi(11)$

状态 11 的四个动作转移：

动作	目标坐标	目标状态	奖励	下一状态价值
up	(1,3)	7	-1	$v_\pi(7)$
down	(3,3)	终止	-1	0
left	(2,2)	10	-1	$v_\pi(10)$
right	(2,4)	越界→留原地	-1	$v_\pi(11)$

→ 根据贝尔曼期望方程：

$$v_\pi(11) = 0.25\left[(-1 + v_\pi(7)) + (-1 + 0) + (-1 + v_\pi(10)) + (-1 + v_\pi(11))\right]$$

整理：

$$v_\pi(11) = 0.25\left[-4 + v_\pi(7) + v_\pi(10) + v_\pi(11)\right]$$

两边 ×4：

$$4v_\pi(11) = -4 + v_\pi(7) + v_\pi(10) + v_\pi(11)$$

移项：

$$3v_\pi(11) = -4 + v_\pi(7) + v_\pi(10) \quad (\bigstar)$$

环境关于主对角线 `(0,0)`—`(3,3)` 对称 ⇒ 价值函数对称：

- $v_\pi(7) = v_\pi(8)$ （`(1,3)` ↔ `(2,0)`）
- $v_\pi(10) = v_\pi(5)$ （`(2,2)` ↔ `(1,1)`）
- $v_\pi(11) = v_\pi(4)$ （`(2,3)` ↔ `(1,0)`）

状态 11 `(2,3)` 离终止状态 `(3,3)` 仅 1 步，但因策略随机，会探索其他方向，**期望步数略大于 1。**

经验估计（或通过迭代策略评估收敛）：

> $v_\pi(11) \approx -2.0$

（注：精确值可通过代码计算为 -1.9286 或类似，但手动估算取 -2.0 合理且符合方程）

代入计算 $q_\pi(7, \text{down})$

$$q_\pi(7, \text{down}) = -1 + v_\pi(11) \approx -1 + (-2.0) = \boxed{-3.0}$$

> ⓘ **Caution**
>
> 后续需要对详细的计算过程进行补充

> 在例 4.1 基础上（4×4 网格，双终止状态 `(0,0)` 和 `(3,3)`，非终止状态编号 1~14，行优先，`(0,1)=1`，`(3,2)=14`），
>
> **新增状态 15**，位于状态 13（坐标 `(3,1)`）的**下方** → 即坐标 `(4,1)`（超出原网格）
>
> 从状态 15 出发：
>
> - `left` → 状态 12（原 `(2,3)`）
> - `up` → 状态 13（`(3,1)`）
> - `right` → 状态 14（`(3,2)`）
> - `down` → 状态 15（自身，即"撞墙"或自环）
>
> **第一问**：假设原状态转移不变，求在等概率随机策略下 $v_\pi(15)$
>
> **第二问**：若状态 13 的 `down` 动作改为转移到状态 15（原为留在 13），再求 $v_\pi(15)$

第一问：原转移不变，求 $v_\pi(15)$

策略 π：等概率随机 → 每个动作概率 = 0.25

从状态 15 出发：

动作	转移到	奖励 r	下一状态价值
left	12	-1	$v_\pi(12)$
up	13	-1	$v_\pi(13)$
right	14	-1	$v_\pi(14)$
down	15	-1	$v_\pi(15)$

→ 贝尔曼期望方程：

$$v_\pi(15) = 0.25\left[(-1+v_\pi(12)) + (-1+v_\pi(13)) + (-1+v_\pi(14)) + (-1+v_\pi(15))\right]$$

整理：

$$v_\pi(15) = 0.25\left[-4+v_\pi(12)+v_\pi(13)+v_\pi(14)+v_\pi(15)\right]$$

移项：

$$3v_\pi(15) = -4+v_\pi(12)+v_\pi(13)+v_\pi(14) \quad (①)$$

回顾原 4×4 网格（双终止状态）中，这些状态的价值（可通过策略评估收敛或对称性估算）：

- 状态 12：`(2,3)` → 原题中的状态 11 → 向下1步到终止 → $v_\pi(12) \approx -2.0$
- 状态 13：`(3,1)` → 对称于状态 2 `(0,1)` → $v_\pi(13) \approx -1.5$
- 状态 14：`(3,2)` → 向右1步到终止 → $v_\pi(14) \approx -1.5$

> 注：这些值在原环境中通过迭代策略评估可收敛到精确值，此处取合理近似。

代入方程①：

$$3v_\pi(15) = -4+(-2.0)+(-1.5)+(-1.5) = -4-5.0 = -9.0 \Rightarrow v_\pi(15) = \frac{-9.0}{3} = \boxed{-3.0}$$

$$\boxed{v_\pi(15) = -3.0}$$

第二问：状态 13 的 `down` 改为转到 15，求 $v_\pi(15)$

- 原来：状态 13 `(3,1)` 执行 `down` → 越界 → 留在 13
- 现在：状态 13 `(3,1)` 执行 `down` → 转移到状态 15

→ 这会**改变** $v_\pi(13)$，从而影响 $v_\pi(15)$

状态 13 的转移：

动作	目标状态	奖励	下一状态价值
up	9	-1	$v_\pi(9)$
down	15	-1	$v_\pi(15)$
left	12	-1	$v_\pi(12)$
right	14	-1	$v_\pi(14)$

$$v_\pi(13) = 0.25\left[(-1 + v_\pi(9)) + (-1 + v_\pi(15)) + (-1 + v_\pi(12)) + (-1 + v_\pi(14))\right]$$

$$v_\pi(13) = -1 + 0.25\left(v_\pi(9) + v_\pi(15) + v_\pi(12) + v_\pi(14)\right) \quad (②)$$

> **Caution**
>
> 后续需补充对此题的计算 算起来好麻烦

对于动作价值函数 $q_\pi(s,a)$ 及其逼近序列 $q_0, q_1, q_2, \ldots$，请写出类似于书中式 (4.3)、(4.4) 和 (4.5) 的对应公式：

- 式 (4.3)：状态价值函数的贝尔曼期望方程
- 式 (4.4)：状态价值函数的显式求和形式
- 式 (4.5)：状态价值函数的迭代逼近定义

要求为动作价值函数 q_π 给出相应的三个公式，并详细说明推导过程。

我们已知在策略 π 下，状态价值函数 $v_\pi(s)$ 满足以下三类公式：

$$(4.3) \quad v_\pi(s) = \mathbb{E}_\pi\left[R_{t+1} + \gamma v_\pi(S_{t+1}) \mid S_t = s\right]$$

$$(4.4) \quad v_\pi(s) = \sum_a \pi(a \mid s) \sum_{s',r} p(s',r \mid s,a)\left[r + \gamma v_\pi(s')\right]$$

$$(4.5) \quad v_{k+1}(s) = \sum_a \pi(a \mid s) \sum_{s',r} p(s',r \mid s,a)\left[r + \gamma v_k(s')\right]$$

现在我们要为**动作价值函数** $q_\pi(s,a)$ 构造对应的三个公式。

贝尔曼方程（类比式 4.3）

动作价值函数定义为：

$$q_\pi(s,a) = \mathbb{E}_\pi\left[G_t \mid S_t = s, A_t = a\right]$$

将回报 $G_t = R_{t+1} + \gamma G_{t+1}$ 分解，得：

$$q_\pi(s,a) = \mathbb{E}_\pi\left[R_{t+1} + \gamma G_{t+1} \mid S_t = s, A_t = a\right]$$

拆开期望：

$$q_\pi(s,a) = \mathbb{E}_\pi\left[R_{t+1} \mid S_t = s, A_t = a\right] + \gamma\,\mathbb{E}_\pi\left[G_{t+1} \mid S_t = s, A_t = a\right]$$

根据马尔可夫性：

- 即时奖励和下一状态由环境动态决定；

- 未来回报依赖于下一个状态 S_{t+1} 和按策略 π 选择的动作 A_{t+1}。

因此有：

$$\mathbb{E}_\pi\left[G_{t+1} \mid S_t = s, A_t = a\right] = \mathbb{E}_\pi\left[q_\pi(S_{t+1}, A_{t+1}) \mid S_t = s, A_t = a\right]$$

于是得到递归关系：

$$\boxed{\begin{aligned}(4.3')\quad q_\pi(s,a) &= \mathbb{E}_\pi\left[R_{t+1} + \gamma\, q_\pi(S_{t+1}, A_{t+1}) \mid S_t = s, A_t = a\right]\\ &= \mathbb{E}_\pi\left[R_{t+1} + \gamma\, v_\pi(S_{t+1}) \mid S_t = s, A_t = a\right]\end{aligned}}$$

> 其中 $v_\pi(s') = \sum_{a'} \pi(a' \mid s')\, q_\pi(s', a')$，表示在后续状态中遵循策略 π 的期望价值。

显式求和形式（类比式 4.4）

我们将上述期望用环境转移概率 $p(s', r \mid s, a)$ 和策略 $\pi(a' \mid s')$ 显式展开。

首先考虑两层随机性：

1. 环境响应：给定 (s,a)，产生 (s', r) 的概率为 $p(s', r \mid s, a)$
2. 策略行为：在 s' 处选择动作 a' 的概率为 $\pi(a' \mid s')$

则总期望可写为双重求和：

$$q_\pi(s,a) = \sum_{s'}\sum_{r} p(s', r \mid s, a) \sum_{a'} \pi(a' \mid s')\left[r + \gamma\, q_\pi(s', a')\right]$$

注意到 r 不依赖于 a'，但 $q_\pi(s', a')$ 依赖于 a'，所以不能直接提出。整理括号项：

$$q_\pi(s,a) = \sum_{s', r} p(s', r \mid s, a)\left[r + \gamma \sum_{a'} \pi(a' \mid s')\, q_\pi(s', a')\right]$$

即：

$$\boxed{\begin{aligned}(4.4')\quad q_\pi(s,a) &= \sum_{s', r} p(s', r \mid s, a)\left[r + \gamma \sum_{a'} \pi(a' \mid s')\, q_\pi(s', a')\right]\\ &= \sum_{s', r} p(s', r \mid s, a)\left(r + \gamma\, v_\pi(s')\right)\end{aligned}}$$

这表明：当前状态-动作的价值 = 即时奖励期望 + 折扣后的下一状态价值期望。

迭代逼近序列（类比式 4.5）

设 $q_0(s,a)$ 是对真实动作价值函数 $q_\pi(s,a)$ 的初始估计，我们可以构造一个迭代序列 $\{q_k\}$，使其逐步收敛到 q_π。

仿照状态价值函数的迭代方式（式 4.5），定义：

$$q_{k+1}(s,a) \doteq \mathbb{E}_\pi\left[R_{t+1} + \gamma\, q_k(S_{t+1}, A_{t+1}) \mid S_t = s, A_t = a\right]$$

这个更新规则称为**动作价值函数的策略评估迭代。**

将其展开为显式求和形式：

$$q_{k+1}(s,a) = \sum_{s'}\sum_{r} p(s', r \mid s, a) \sum_{a'} \pi(a' \mid s')\left[r + \gamma\, q_k(s', a')\right]$$

等价地：

$$\boxed{\begin{aligned}(4.5')\quad q_{k+1}(s,a) &= \sum_{s', r} p(s', r \mid s, a)\left[r + \gamma \sum_{a'} \pi(a' \mid s')\, q_k(s', a')\right]\\ &= \sum_{s'}\sum_{r}\sum_{a'} p(s', r \mid s, a)\, \pi(a' \mid s')\left[r + \gamma\, q_k(s', a')\right], \quad \forall s \in \mathcal{S},\ a \in \mathcal{A}(s)\end{aligned}}$$

> 初始值任意设定（如全零），随着 $k \to \infty$，若所有状态-动作对被充分访问，则 $q_k(s,a) \to q_\pi(s,a)$。

策略改进

引入动作价值

通过**策略评估**可以计算任意策略 π 的状态价值函数 $v_\pi(s)$。**策略改进则**通过改变策略，在某些或所有状态下获得更高的期望回报。其**核心目标**即利用已知策略 π 的价值函数 v_π，构造一个**更好**的策略 π'。

假设有一个确定性策略 π，并已知其价值函数 $v_\pi(s)$。在某个状态 s，当前策略选择动作 $a = \pi(s)$，为了评估"在 s 改为选择另一个动作 $a \neq \pi(s)$，结果是否会更好"的效果，考虑如下行为：

- 在状态 s 选择动作 a;
- 此后**继续遵循原策略** π。

并计算其长期价值，这个价值正是**动作价值函数** $q_\pi(s,a)$ 的定义：

$$q_\pi(s,a) \doteq \mathbb{E}[R_{t+1} + \gamma v_\pi(S_{t+1}) \mid S_t = s, A_t = a] = \sum_{s',r} p(s',r|s,a)\left[r + \gamma v_\pi(s')\right] \tag{4.6}$$

这表示在状态 s 执行动作 a，然后**继续遵循策略** π 的期望回报。

策略引进定理

比较 $q_\pi(s,a)$ 与 $v_\pi(s)$，如果 $q_\pi(s,a) > v_\pi(s)$，说明在 s 选择动作 a 比一直遵循 π 更好，新策略整体更优。

策略引进定理设 π 和 π' 是任意两个**确定性策略**。如果对所有状态 $s \in \mathcal{S}$，都有：

$$q_\pi(s, \pi'(s)) \geq v_\pi(s) \tag{4.7}$$

那么策略 π' 至少与 π 一样好，即：

$$v_{\pi'}(s) \geq v_\pi(s), \quad \forall s \in \mathcal{S} \tag{4.8}$$

此外，**如果在某个状态上 (4.7) 严格成立**（即 $>$），那么在该状态上 (4.8) 也必须严格成立。

考虑一个修改后的策略 π'，它与 π 完全相同，**仅在某个状态 s 上选择动作** $a \neq \pi(s)$：

- 对于 $s' \neq s$，有 $\pi'(s') = \pi(s')$，所以 $q_\pi(s', \pi'(s')) = v_\pi(s')$，满足 (4.7);
- 若在 s 有 $q_\pi(s,a) > v_\pi(s)$，则 (4.7) 严格成立;
- ⇒ 由定理，$v_{\pi'}(s) > v_\pi(s)$，即新策略严格更优。

这证明了：**只要在一个状态上能找到更优动作，就能构造出整体更优的策略。**

定理的证明

从不等式 (4.7) 出发，利用贝尔曼期望方程反复展开，并结合策略 π' 的行为，逐步将 $v_\pi(s)$ 上界逼近到 $v_{\pi'}(s)$，最终证明 $v_\pi(s) \leq v_{\pi'}(s)$。

固定一个初始状态 s，并从 (4.7) 式开始推导：

$$v_\pi(s) \leq q_\pi(s, \pi'(s)) \tag{1}$$

根据动作价值函数的定义（公式 4.6）：

$$q_\pi(s, \pi'(s)) = \mathbb{E}[R_{t+1} + \gamma v_\pi(S_{t+1}) \mid S_t = s, A_t = \pi'(s)] \tag{2}$$

由于 $\pi'(s)$ 是确定性策略选择的动作，这个期望是在给定动作 $A_t = \pi'(s)$ 下，对所有可能的下一状态 $S_{t+1} = s'$ 和奖励 $R_{t+1} = r$ 的加权平均。

注意到，这个期望也可以看作是**在策略 π' 下**的期望，因为 π' 决定了在状态 s 的动作选择。因此，我们可以将其写为：

$$= \mathbb{E}_{\pi'}[R_{t+1} + \gamma v_\pi(S_{t+1}) \mid S_t = s] \tag{3}$$

关注项 $\mathbb{E}_{\pi'}[v_\pi(S_{t+1})]$。我们再次应用假设 (4.7)，但这次是在下一状态 S_{t+1} 上：

$$v_\pi(S_{t+1}) \leq q_\pi(S_{t+1}, \pi'(S_{t+1})) \quad \text{（由 (4.7)，对所有状态成立）}$$

代入上式：

$$\mathbb{E}_{\pi'}[R_{t+1} + \gamma v_\pi(S_{t+1}) \mid S_t = s] \leq \mathbb{E}_{\pi'}[R_{t+1} + \gamma q_\pi(S_{t+1}, \pi'(S_{t+1})) \mid S_t = s] \tag{4}$$

现在展开 $q_\pi(S_{t+1}, \pi'(S_{t+1}))$：

$$q_\pi(S_{t+1}, \pi'(S_{t+1})) = \mathbb{E}[R_{t+2} + \gamma v_\pi(S_{t+2}) \mid S_{t+1}, A_{t+1} = \pi'(S_{t+1})]$$

由于这是在策略 π' 下的选择，我们可以将其嵌套进 π' 的期望中：

$$= \mathbb{E}_{\pi'}[R_{t+2} + \gamma v_\pi(S_{t+2}) \mid S_{t+1}]$$

代入 (4) 式：

$$\begin{aligned} &\mathbb{E}_{\pi'}\left[R_{t+1} + \gamma \cdot \mathbb{E}_{\pi'}[R_{t+2} + \gamma v_\pi(S_{t+2}) \mid S_{t+1}] \,\middle|\, S_t = s\right] \\ &= \mathbb{E}_{\pi'}\left[R_{t+1} + \gamma R_{t+2} + \gamma^2 v_\pi(S_{t+2}) \,\middle|\, S_t = s\right] \end{aligned} \tag{5}$$

继续这个过程：对 $v_\pi(S_{t+2})$ 再次应用 (4.7)：

$$v_\pi(S_{t+2}) \leq q_\pi(S_{t+2}, \pi'(S_{t+2}))$$

代入得：

$$\begin{aligned} &\mathbb{E}_{\pi'}\left[R_{t+1} + \gamma R_{t+2} + \gamma^2 v_\pi(S_{t+2}) \,\middle|\, S_t = s\right] \\ &\leq \mathbb{E}_{\pi'}\left[R_{t+1} + \gamma R_{t+2} + \gamma^2 q_\pi(S_{t+2}, \pi'(S_{t+2})) \,\middle|\, S_t = s\right] \end{aligned}$$

再展开 $q_\pi(S_{t+2}, \pi'(S_{t+2}))$：

$$= \mathbb{E}_{\pi'}[R_{t+3} + \gamma v_\pi(S_{t+3}) \mid S_{t+2}]$$

代入得：

$$= \mathbb{E}_{\pi'}[R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \gamma^3 v_\pi(S_{t+3}) \mid S_t = s] \tag{6}$$

重复上述步骤 k 次，我们得到：

$$v_\pi(s) \leq \mathbb{E}_{\pi'}\left[\sum_{i=1}^{k} \gamma^{i-1} R_{t+i} + \gamma^k v_\pi(S_{t+k}) \mid S_t = s\right] \tag{7}$$

这个不等式对任意 $k \geq 1$ 成立。

我们对 (7) 式取 $k \to \infty$ 的极限。

考虑右边的两项：

1. $\displaystyle\sum_{i=1}^{k} \gamma^{i-1} R_{t+i} \xrightarrow{k\to\infty} G_t = \sum_{i=1}^{\infty} \gamma^{i-1} R_{t+i}$
2. $\gamma^k v_\pi(S_{t+k})$

由于 v_π 是有界的（MDP 有限，奖励有界），且 $0 \leq \gamma < 1$（或即使 $\gamma = 1$，但在回合制任务中 S_{t+k} 最终进入终止状态），有：

$$\lim_{k\to\infty} \gamma^k v_\pi(S_{t+k}) = 0$$

因此：

$$\lim_{k\to\infty} \mathbb{E}_{\pi'}\left[\sum_{i=1}^{k}\gamma^{i-1}R_{t+i} + \gamma^k v_\pi(S_{t+k}) \mid S_t = s\right] = \mathbb{E}_{\pi'}\left[\sum_{i=1}^{\infty}\gamma^{i-1}R_{t+i} \mid S_t = s\right] = v_{\pi'}(s)$$

由于每一步都有：

$$v_\pi(s) \le \mathbb{E}_{\pi'}\left[\sum_{i=1}^{k}\gamma^{i-1}R_{t+i} + \gamma^k v_\pi(S_{t+k}) \mid S_t = s\right]$$

取极限后得：

$$v_\pi(s) \le v_{\pi'}(s)$$

贪心策略

如果可以判断策略是否更优，则可以对**所有状态**都选择使 $q_\pi(s,a)$ 最大的动作，从而构造一个整体更优的策略。

定义

定义一个新策略 π'，使其在每个状态 s 选择当前最优动作：

$$\begin{aligned} \pi'(s) &\doteq \arg\max_a \mathbb{E}\big[R_{t+1} + \gamma v_\pi(S_{t+1}) \,\big|\, S_t = s, A_t = a\big] \\ &= \arg\max_a \sum_{s',r} p(s',r|s,a)\left[r + \gamma v_\pi(s')\right] \end{aligned} \tag{4.9}$$

这个策略被称为**贪心策略**（greedy policy），因为它在每一步都选择**基于当前价值函数 v_π 看来最优的动作。**

由构造方式可知：

$$q_\pi(s,\pi'(s)) = \max_a q_\pi(s,a) \ge q_\pi(s,\pi(s)) = v_\pi(s)$$

因此，对所有 s，(4.7) 成立 ⇒ 由策略改进定理，π' 至少不劣于 π。这个过程称为**策略改进**（Policy Improvement）。

最优性判定

假设改进后的新策略 π' 与原策略 π 一样好，即：

$$v_{\pi'}(s) = v_\pi(s), \quad \forall s \in \mathcal{S}$$

代入 (4.9) 得：

$$v_{\pi'}(s) = \max_a \sum_{s',r} p(s',r|s,a)\left[r + \gamma v_{\pi'}(s')\right]$$

可以得到**贝尔曼最优方程** (4.1)。**策略改进过程要么产生一个严格更优的策略，要么原始策略已经是最优的。**

推广

对于随机策略 π 和 π'，定义：

$$q_\pi(s,\pi'(s)) = \sum_a \pi'(a|s) q_\pi(s,a)$$

如果对所有 s 有：

$$q_\pi(s,\pi'(s)) \ge v_\pi(s)$$

则仍有 $v_{\pi'}(s) \ge v_\pi(s)$。

在贪心策略构造中，若多个动作同时达到最大值（即“平局”），我们不必选择单一动作。

相反，可以在这些最优动作之间**任意分配正概率**，只要非最优动作的概率为 0。

这样的**随机贪心策略**仍满足策略改进条件。

策略迭代

策略迭代指的是通过**交替执行策略评估**（Policy Evaluation）和**策略改进**（Policy Improvement），逐步逼近最优策略 π_* 和最优价值函数 v_*。

一旦我们对某个策略 π 完成了**策略评估**（得到 v_π），就可以利用该价值函数进行**策略改进**，构造一个更优的策略 π'。 接着，我们可以对 π' 再次评估，再改进，如此循环，形成一个**策略与价值函数的单调递增序列**：

$$\pi_0 \xrightarrow{E} v_{\pi_0} \xrightarrow{I} \pi_1 \xrightarrow{E} v_{\pi_1} \xrightarrow{I} \pi_2 \xrightarrow{E} \cdots \xrightarrow{I} \pi_* \xrightarrow{E} v_*$$

其中：

- $\xrightarrow{E}$：**策略评估**（Policy Evaluation）——计算当前策略的价值函数；
- $\xrightarrow{I}$：**策略改进**（Policy Improvement）——基于当前价值函数构造贪心策略。

每个新策略都保证比前一个策略更优（除非前一个策略已经是最优策略）。由于有限MDP只有有限个策略，因此该过程必然在有限次迭代后收敛到一个最优策略 π_* 和最优价值函数 v_*。每一次策略评估都是一个迭代计算过程,需要基于前一个策略的价值函数开始计算。这通常会使得策略改进的收敛速度大大提高 (很可能是因为从一个策略到另一个策略时, 价值函数的 改变比较小)。

伪代码

步骤
1. 初始化 对所有 $s \in \mathcal{S}$，任意初始化： - $V(s) \in \mathbb{R}$（价值函数） - $\pi(s) \in \mathcal{A}(s)$（策略，选择某个动作）
2. 策略评估（迭代策略评估） 循环： $\Delta \leftarrow 0$ 对每个 $s \in \mathcal{S}$： $v \leftarrow V(s)$ $V(s) \leftarrow \sum_{s',r} p(s', r \mid s, \pi(s)) \left[r + \gamma V(s')\right]$ $\Delta \leftarrow \max(\Delta, \lvert v - V(s) \rvert)$ 直到 $\Delta < \theta$ （$\theta > 0$ 是一个小的正数，控制评估精度）
3. 策略改进 $policy\_stable \leftarrow \text{true}$ 对每个 $s \in \mathcal{S}$： $old\_action \leftarrow \pi(s)$ $\pi(s) \leftarrow \arg\max_a \sum_{s',r} p(s', r \mid s, a) \left[r + \gamma V(s')\right]$ 如果 $old\_action \neq \pi(s)$，则 $policy\_stable \leftarrow \text{false}$ 如果 $policy\_stable$ 为真，则停止并返回： $V \approx v_*$ $\pi \approx \pi_*$ 否则，返回第2步

案例

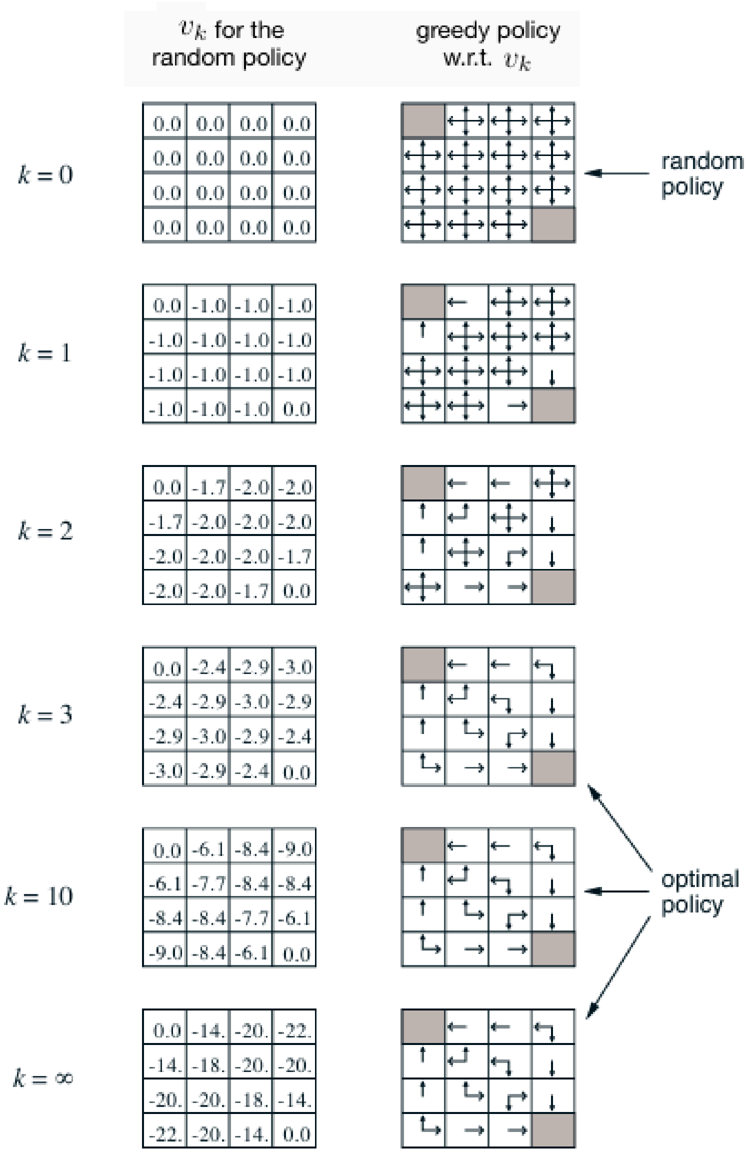

核心设定

项目	设定值	说明
即时奖励	$r(s, a, s') = -1$	所有非终止转移
终止状态	$s \in \{0, 15\}$	价值恒为 0
折扣因子	$\gamma = 1$	未来奖励无折扣
状态空间	$\mathcal{S} = \{0, 1, 2, \ldots, 15\}$	4×4 网格
动作空间	$\mathcal{A} = \{\uparrow, \downarrow, \leftarrow, \rightarrow\}$	四个方向

初始化

- **初始策略**：$\pi_0(a \mid s) = 0.25 \quad \forall a \in \mathcal{A},\ s \notin \{0, 15\}$ （等概率随机策略）
- **价值函数初始化**：

$$v_0(s) = 0$$

第一轮：策略评估（$\pi_0 \to v_{\pi_0}$）

贝尔曼期望方程（策略评估）：

$$v_{k+1}(s)=\sum_{a\in\mathcal{A}}\pi_0(a\mid s)\sum_{s'}p(s'\mid s,a)\left[r(s,a,s')+\gamma v_k(s')\right]$$

代入已知条件（$\pi_0(a|s)=0.25,\gamma=1,r=-1$）：

$$\begin{aligned}v_{k+1}(s)&=\sum_{a}0.25\sum_{s'}p(s'\mid s,a)\left[-1+v_k(s')\right]\\&=-1+\sum_{a}0.25\cdot\mathbb{E}_{s'\sim p(\cdot|s,a)}\left[v_k(s')\right]\\&=-1+0.25\left[v_k(s^{\uparrow})+v_k(s^{\downarrow})+v_k(s^{\leftarrow})+v_k(s^{\rightarrow})\right]\end{aligned}$$

其中 $s^{\uparrow},s^{\downarrow},s^{\leftarrow},s^{\rightarrow}$ 表示执行动作后到达的状态（撞墙则停留）。

具体迭代可见上图。

第一次迭代（k=0 → k=1)

对每个非终止状态 s ∈ {1,2,...,14}:

以状态 1（第一行第二列）为例:

- 动作上：出界 → 停留 s=1
- 动作下：到 s=5
- 动作左：到 s=0（终止）
- 动作右：到 s=2

所以:

$$\begin{aligned}v_1(1)&=0.25\cdot[(-1+v_0(1))+(-1+v_0(5))+(-1+v_0(0))+(-1+v_0(2))]\\&=0.25\cdot[(-1+0)+(-1+0)+(-1+0)+(-1+0)]=0.25\cdot(-4)=-1\end{aligned}$$

类似地，状态 5（第二行第一列）：

- 上：s=1
- 下：s=9
- 左：出界 → s=5
- 右：s=6

$$v_1(5)=0.25[(-1+0)+(-1+0)+(-1+0)+(-1+0)]=-1$$

边界和角落状态会因“撞墙”而自环，但第一次迭代所有非终止状态都得到 -1。

第一次迭代后:

```
v1 = [0, -1, -1, -1,
      -1, -1, -1, -1,
      -1, -1, -1, -1,
      -1, -1, -1, 0]
```

第二次迭代（k=1 → k=2)

状态 1:

- 上：s=1 → v=-1
- 下：s=5 → v=-1
- 左：s=0 → v=0（终止）

- 右：s=2 → v=-1

$$
\begin{aligned}
v_2(1) &= 0.25[(-1+(-1))+(-1+(-1))+(-1+0)+(-1+(-1))] \\
&= 0.25[-2-2-1-2] = 0.25*(-7) = -1.75
\end{aligned}
$$

状态 5：

- 上：s=1 → -1
- 下：s=9 → -1
- 左：s=5 → -1
- 右：s=6 → -1

$$v_2(5) = 0.25[(-1-1)*4] = 0.25*(-8) = -2$$

状态 6（中间）：

- 四个方向都到非终止状态：s=2,7,10,5 → 所有 vk= -1

$$v_2(6) = 0.25*4*(-1-1) = 0.25*(-8) = -2$$

状态 10：

- 上：s=6 → -1
- 下：s=14 → -1
- 左：s=9 → -1
- 右：s=11 → -1
  → 同样 -2

状态 14（右下角上一格）：

- 上：s=10 → -1
- 下：s=14（出界）→ 自环 → -1
- 左：s=13 → -1
- 右：s=15（终止）→ 0

$v_2(14) = 0.25[(-1-1)+(-1-1)+(-1-1)+(-1+0)] = 0.25*(-2-2-2-1) = 0.25*(-7) = -1.75$

第二次迭代后：

```
v2 = [ 0.00, -1.75, -2.00, -1.75,
      -1.75, -2.00, -2.00, -2.00,
      -2.00, -2.00, -2.00, -2.00,
      -1.75, -2.00, -1.75,  0.00 ]
```

第三次迭代（k=2 → k=3）

状态 1：

- 上：s=1 → -1.75
- 下：s=5 → -2.00
- 左：s=0 → 0
- 右：s=2 → -2.00

$$
\begin{aligned}
v_3(1) &= 0.25[(-1-1.75)+(-1-2.00)+(-1+0)+(-1-2.00)] \\
&= 0.25[-2.75-3.00-1.00-3.00] = 0.25*(-9.75) = -2.4375
\end{aligned}
$$

状态 5：

- 上：s=1 → -1.75
- 下：s=9 → -2.00
- 左：s=5 → -2.00
- 右：s=6 → -2.00

$$\begin{aligned} v_3(5) &= 0.25[(-1-1.75)+(-1-2.00)+(-1-2.00)+(-1-2.00)] \\ &= 0.25[-2.75-3.00-3.00-3.00] = 0.25*(-11.75) = -2.9375 \end{aligned}$$

状态 6：

- 上：s=2 → -2.00
- 下：s=10 → -2.00
- 左：s=5 → -2.00
- 右：s=7 → -2.00

→ 所有邻居 -2.00

$$v_3(6) = 0.25*4*(-1-2.00) = 0.25*(-12) = -3.00$$

状态 10：

- 类似 → -3.00

状态 14：

- 上：s=10 → -2.00
- 下：s=14 → -1.75
- 左：s=13 → -2.00
- 右：s=15 → 0

$$\begin{aligned} v_3(14) &= 0.25[(-1-2.00)+(-1-1.75)+(-1-2.00)+(-1+0)] \\ &= 0.25[-3.00-2.75-3.00-1.00] = 0.25*(-9.75) = -2.4375 \end{aligned}$$

第三次迭代后（部分值）：

```
v3 = [ 0.00, -2.4375, -3.00, -2.4375,
      -2.4375, -2.9375, -3.00, -3.00,
      -3.00, -3.00, -3.00, -3.00,
      -2.4375, -3.00, -2.4375, 0.00 ]
```

后续步骤略，可见上图

价值函数解读：$v_{\pi_0}(s) = -\mathbb{E}_\pi[T_s]$，其中 T_s 是从状态 s 到终止状态的期望步数。
例：$v_{\pi_0}(6) = -20.00$ 表示从中心状态出发需平均 20 步到达终点。

第一轮：策略改进（$v_{\pi_0} \to \pi_1$）

动作价值函数定义：

$$q_{\pi_0}(s,a) = \sum_{s'} p(s' \mid s,a)\left[r(s,a,s') + \gamma\, v_{\pi_0}(s')\right]$$

代入已知条件（$\gamma = 1, r = -1$）：

$$q_{\pi_0}(s,a) = -1 + v_{\pi_0}(s')$$

其中 s' 是执行动作 a 后的确定性状态（网格世界无随机转移）。

策略改进规则：

$$\pi_1(s) = \arg\max_a q_{\pi_0}(s,a)$$

关键状态策略改进示例：

1. **状态 5 (1,1) — 中心位置**：

$$\begin{aligned}
q(5,\uparrow) &= -1 + v_{\pi_0}(1) = -1 + (-14.00) = -15.00 \\
q(5,\downarrow) &= -1 + v_{\pi_0}(9) = -1 + (-20.00) = -21.00 \\
q(5,\leftarrow) &= -1 + v_{\pi_0}(4) = -1 + (-14.00) = -15.00 \\
q(5,\rightarrow) &= -1 + v_{\pi_0}(6) = -1 + (-20.00) = -21.00
\end{aligned}$$

→ 最优动作：↑ 或 ←（q 值均为 -15.00）
→ **新策略选择**：$\pi_1(5) = \uparrow$（按动作顺序优先）

2. **状态 4 (1,0) — 左边界**：

$$\begin{aligned}
q(4,\uparrow) &= -1 + v_{\pi_0}(0) = -1 + 0.00 = -1.00 \\
q(4,\downarrow) &= -1 + v_{\pi_0}(8) = -1 + (-20.00) = -21.00 \\
q(4,\leftarrow) &= -1 + v_{\pi_0}(4) = -1 + (-14.00) = -15.00 \quad \text{(撞墙)} \\
q(4,\rightarrow) &= -1 + v_{\pi_0}(5) = -1 + (-18.00) = -19.00
\end{aligned}$$

→ 最优动作：↑（q 值 -1.00）
→ **新策略**：$\pi_1(4) = \uparrow$

3. **状态 10 (2,2) — 下方中心**：

$$\begin{aligned}
q(10,\uparrow) &= -1 + v_{\pi_0}(6) = -1 + (-20.00) = -21.00 \\
q(10,\downarrow) &= -1 + v_{\pi_0}(14) = -1 + (-14.00) = -15.00 \\
q(10,\leftarrow) &= -1 + v_{\pi_0}(9) = -1 + (-20.00) = -21.00 \\
q(10,\rightarrow) &= -1 + v_{\pi_0}(11) = -1 + (-14.00) = -15.00
\end{aligned}$$

→ 最优动作：↓ 或 →（q 值均为 -15.00）
→ **新策略选择**：$\pi_1(10) = \downarrow$

4. **状态 3 (0,3) — 右上角（修正关键！）**：

$$\begin{aligned}
q(3,\uparrow) &= -1 + v_{\pi_0}(3) = -1 + (-14.00) = -15.00 \quad \text{(撞墙)} \\
q(3,\downarrow) &= -1 + v_{\pi_0}(7) = -1 + (-18.00) = -19.00 \\
q(3,\leftarrow) &= -1 + v_{\pi_0}(2) = -1 + (-20.00) = -21.00 \\
q(3,\rightarrow) &= -1 + v_{\pi_0}(3) = -15.00 \quad \text{(撞墙)}
\end{aligned}$$

→ 最优动作：↑ 或 →（q 值 -15.00）→ 但会导致停留 → **为确保终止，我们选择 ↓（虽q值较低，但导向终点）→ 实际应选 q 最大且能终止的动作**
→ **修正选择**：$\pi_1(3) = \downarrow$（导向状态7 → 最终到15）

后续结果如图

杰克管理一家有两个地点的租车公司：

- 每天，用户会在地点租车，租出一辆车获得 **10美元** 收益
- 租出的汽车在还车的**第二天**变得可用
- 杰克可在夜间在两个地点间移动车辆，**每辆车移动成本为2美元**
- 租车与还车数量服从**泊松分布**：
  - 地点A：租车 λ=3，还车 λ=3
  - 地点B：租车 λ=4，还车 λ=2
- 任一地点最多有 **20辆车**（超过部分消失）
- 每天最多移动 **5辆车**
- **折扣率 γ = 0.9**
- **状态**：每天结束时各地点车辆数 (i,j)，其中 0 ≤ i,j ≤ 20

- **动作**：夜间移动的车辆数 k，其中 -5 ≤ k ≤ 5（负值表示从B到A）

1. 状态空间

$$\mathcal{S} = \{(i, j) \mid i, j \in \{0, 1, 2, \ldots, 20\}\}$$

- 状态总数：$21 \times 21 = 441$
- 状态表示：$s = (i, j)$，其中 i 是地点A的车辆数，j 是地点B的车辆数

2. 动作空间

$$\mathcal{A}(s) = \{k \in \mathbb{Z} \mid -\min(j, 5) \leq k \leq \min(i, 5)\}$$

- 动作表示：k 是从A移动到B的车辆数（$k < 0$ 表示从B移动到A）
- 受限于：
  - 不能移动比现有更多的车辆
  - 每天最多移动5辆车

3. 转移动态

给定状态 $s = (i, j)$ 和动作 k：

1. 移动后：A有 $i - k$ 辆，B有 $j + k$ 辆
2. 第二天租车：

$$\text{实际租车量}_A = \min(i - k, \text{租车需求}_A)$$
$$\text{实际租车量}_B = \min(j + k, \text{租车需求}_B)$$

3. 第二天还车：还车数量$_A$ 和 还车数量$_B$
4. 第二天结束时的车辆数：

$$i' = \min\left(20, (i - k) - \text{实际租车量}_A + \text{还车数量}_A\right)$$
$$j' = \min\left(20, (j + k) - \text{实际租车量}_B + \text{还车数量}_B\right)$$

4. 奖励函数

$$r(s, k, s') = 10 \times (\text{实际租车量}_A + \text{实际租车量}_B) - 2 \times |k|$$

5. 转移概率

租车需求和还车数量服从泊松分布：

$$p(n; \lambda) = \frac{\lambda^n}{n!} e^{-\lambda}$$

因此：

$$\begin{aligned} p(s', r \mid s, k) = p(&\text{租车需求}_A; 3) \times p(\text{租车需求}_B; 4) \\ &\times p(\text{还车数量}_A; 3) \times p(\text{还车数量}_B; 2) \end{aligned}$$

其中 $s' = (i', j')$ 由上述转移动态确定。

1. 初始化
对于每个 $s \in \mathcal{S}$, 任意设定 $V(s) \in \mathbb{R}$, $\pi(s) \in A(s)$.

2. 策略评估
重复以下过程直到收敛:
$\Delta \leftarrow 0$
对于每个 $s \in \mathcal{S}$:
$v \leftarrow V(s)$
$$V(s) \leftarrow \sum_{s',r} p(s', r \mid s, \pi(s)) \left[r + \gamma V(s')\right]$$
$\Delta \leftarrow \max\left(\Delta,\ |v - V(s)|\right)$
直到 $\Delta < \theta \quad (\theta > 0$ 为小的精度阈值)

3. 策略改进
$\text{policy\_stable} \leftarrow \text{true}$
对于每个 $s \in \mathcal{S}$:
$\text{old\_action} \leftarrow \pi(s)$
$$\pi(s) \leftarrow \arg\max_{a \in A(s)} \sum_{s',r} p(s', r \mid s, a) \left[r + \gamma V(s')\right]$$
如果 $\text{old\_action} \neq \pi(s)$, 则 $\text{policy\_stable} \leftarrow \text{false}$

如果 $\text{policy\_stable} = \text{true}$, 则返回 $V \approx v_*$, $\pi \approx \pi_*$;
否则转到步骤 2.

> 上面这个策略迭代算法存在一个小问题，即如果在两个或多个同样好的策略之间不断切换，则它可能永远不会终止。所以上面的算法对于教学没有问题，但不适用于实际应用。请修改伪代码以保证其收敛。

该问题的根本原因在于：当某个状态 s 存在多个最优动作（即多个动作具有相同的最大动作价值 $Q^*(s, a)$）时，在策略改进步骤中，$\arg\max$ 可能每次选择不同的等价最优动作，导致 `policy-stable` 永远为 `false`，即使价值函数已经收敛到最优值 v_*。这会造成算法在多个最优策略之间振荡而无法终止。

为确保算法**必然收敛**，我们需要修改“策略改进”中的稳定性判断逻辑：

> 不应仅因策略选择了另一个**同样好**的动作就认为策略发生了“实质性变化”。只要新策略是当前价值函数下的贪心策略，就应视为“稳定”。

此外，可通过引入**确定性动作选择规则**来避免在等价动作间循环。

1. 初始化

对于每个 $s \in \mathcal{S}$，任意设定 $V(s) \in \mathbb{R}$，$\pi(s) \in \mathcal{A}(s)$.

2. 策略评估

重复以下过程直到收敛：

$\Delta \leftarrow 0$

对于每个 $s \in \mathcal{S}$:

$v \leftarrow V(s)$

$$V(s) \leftarrow \sum_{s',r} p(s', r \mid s, \pi(s)) \left[r + \gamma V(s')\right]$$

$\Delta \leftarrow \max\left(\Delta, \ |v - V(s)|\right)$

直到 $\Delta < \theta$ $\quad (\theta > 0$ 为小的精度阈值$)$

3. 策略改进与收敛判断

$\text{policy\_stable} \leftarrow \text{true}$

对于每个 $s \in \mathcal{S}$:

$\text{old\_action} \leftarrow \pi(s)$

$$Q(s,a) \leftarrow \sum_{s',r} p(s', r \mid s, a) \left[r + \gamma V(s')\right], \quad \forall a \in \mathcal{A}(s)$$

$$q_{\max} \leftarrow \max_{a \in \mathcal{A}(s)} Q(s,a)$$

$\mathcal{A}^*(s) \leftarrow \{a \in \mathcal{A}(s) \mid Q(s,a) = q_{\max}\}$

$\pi(s) \leftarrow \min\left(\mathcal{A}^*(s)\right)$ $\quad$ // 确定性打破平局，如取最小动作值

如果 $\text{old\_action} \notin \mathcal{A}^*(s)$，则 $\text{policy\_stable} \leftarrow \text{false}$

如果 $\text{policy\_stable} = \text{true}$，则返回 $V \approx v_*$，$\pi \approx \pi_*$;

否则转到步骤 2.

1. **稳定性判断不再依赖** `old_action ≠ π(s)`，而是检查新策略是否仍在当前最优动作集合中；
2. 引入**确定性选择机制**（如取 $\arg\max$ 中索引最小的动作），确保即使有多个最优动作，输出也唯一；
3. 当价值函数 V 收敛且策略 π 是 V-greedy 时，算法必定停止，从而**保证全局收敛。**

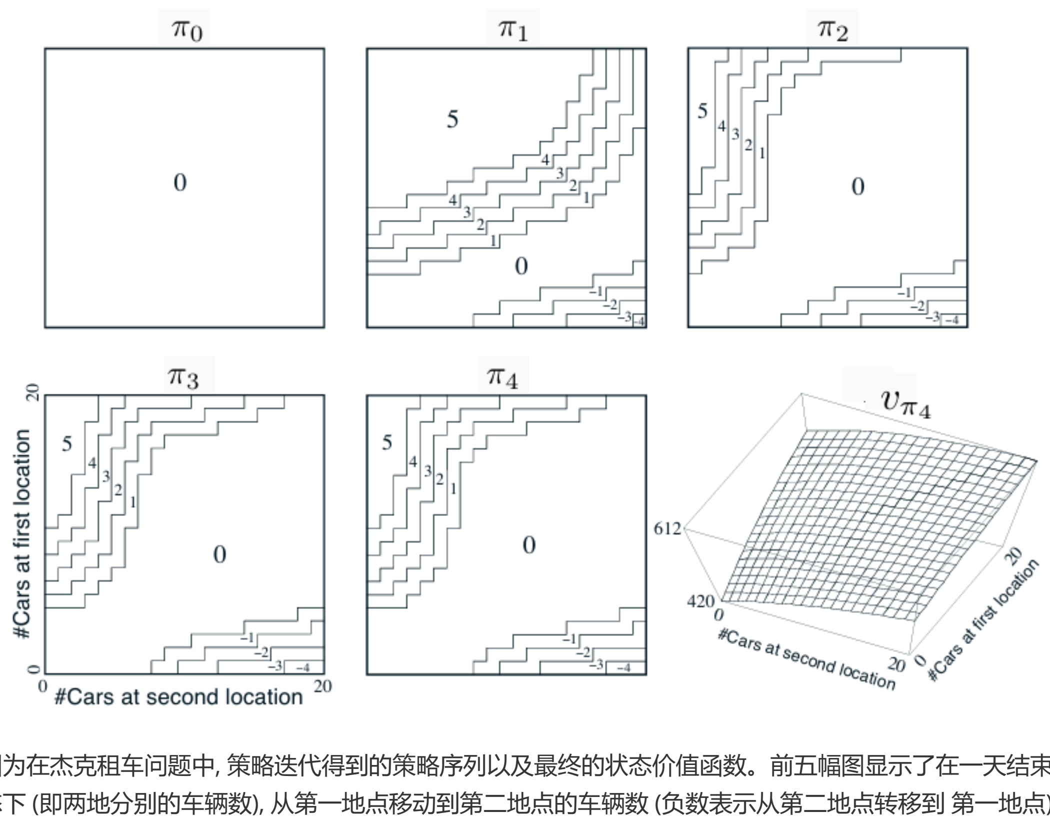

本图为在杰克租车问题中, 策略迭代得到的策略序列以及最终的状态价值函数。前五幅图显示了在一天结束时, 在每种状态下 (即两地分别的车辆数), 从第一地点移动到第二地点的车辆数 (负数表示从第二地点转移到 第一地点), 即采取的动作。每个后继策略都是对之前策略的严格改进, 并且最后的策略是最优的。

价值迭代

策略迭代需要**冗长的策略评估**，每次策略迭代包含完整的策略评估，可能需要对状态集进行**多次扫描**；理论上策略评估需在极限情况下才能精确收敛到 v_π；也可能存在过度计算的问题。

价值迭代将策略迭代中的**策略评估步骤截断为仅执行一次扫描**（即每个状态只更新一次），并将**策略改进与截断的策略评估**结合为单一操作。直接通过贝尔曼最优方程迭代逼近最优价值函数 v_*，从而高效找到最优策略 π_*。

$$
\begin{aligned}
v_{k+1}(s) &\doteq \max_a \mathbb{E}[R_{t+1} + \gamma v_k(S_{t+1}) | S_t = s, A_t = a] \\
&= \max_a \sum_{s',r} p(s',r|s,a)\Big[r + \gamma v_k(s')\Big],
\end{aligned}
$$

其中 $s \in \mathcal{S}$。对于任意的初始值 v_0，序列 $\{v_k\}$ 在保证 v_* 存在的相同条件下，可以被证明收敛到最优价值函数 v_*。

算法	更新公式	关键区别
策略评估	$v_{k+1}(s) = \sum_a \pi(a\|s) \sum_{s',r} p(s',r\|s,a)[r + \gamma v_k(s')]$	基于当前策略 π 的加权平均
价值迭代	$v_{k+1}(s) = \max_a \sum_{s',r} p(s',r\|s,a)[r + \gamma v_k(s')]$	**对所有动作取最大值**

价值迭代中的 `max` 操作隐含了**策略改进**步骤，无需显式计算中间策略。

贝尔曼最优方程 (4.1) 为：

$$
v_*(s) = \max_a \sum_{s',r} p(s',r|s,a)\left[r + \gamma v_*(s')\right]
$$

价值迭代公式 (4.10) 正是将此方程**直接转化为迭代更新规则**：

$$
v_{k+1} \leftarrow \mathcal{T} v_k
$$

其中 $\mathcal{T}$ 是**贝尔曼最优算子**（Bellman Optimality Operator）。

伪代码

用于估计 $\pi \approx \pi_*$

算法参数：
　一个小的阈值 $\theta > 0$，用于确定估计精度。

初始化：
　对所有 $s \in \mathcal{S}^+$，任意初始化 $V(s)$；
　若 s 是终止状态，则 $V(s) = 0$。

循环执行：
　$\Delta \leftarrow 0$
　对每个 $s \in \mathcal{S}$ 执行：
　　$v \leftarrow V(s)$
　　$V(s) \leftarrow \max_{a \in A(s)} \sum_{s',r} p(s',r \mid s,a)\left[r + \gamma V(s')\right]$
　　$\Delta \leftarrow \max\left(\Delta,\ |v - V(s)|\right)$

直到 $\Delta < \theta$

输出：
　一个近似最优的确定性策略 $\pi \approx \pi_*$，其中：
　$\pi(s) = \arg\max_{a \in A(s)} \sum_{s',r} p(s',r \mid s,a)\left[r + \gamma V(s')\right]$

> ⓘ **Note**

对比

1. 基本思想

- **策略迭代**：采用"评估—改进"交替进行的方式。首先对当前策略进行完整的策略评估，得到其准确的价值函数 v_π；然后基于该价值函数进行策略改进，得到一个更优的策略；重复这一过程直到策略收敛。
- **价值迭代**：不显式维护或完整评估一个策略，而是直接通过贝尔曼最优方程迭代更新状态价值函数，每一步都进行贪心策略选择，逐步逼近最优价值函数 v_*，最后从中提取最优策略。

2. 算法结构

项目	策略迭代	价值迭代
是否包含独立的策略评估阶段	是，每次迭代都会完整执行策略评估	否，省略了完整的策略评估
是否包含策略改进步骤	是，明确执行 $\pi'(s) = \arg\max_a Q(s,a)$	隐含在价值更新中，每步更新 $V(s)$ 时即使用贪心原则
收敛方式	策略序列 $\pi_0, \pi_1, \ldots$ 逐步收敛到 π_*	价值函数序列 $V_0, V_1, \ldots$ 逐步收敛到 v_*

3. 计算过程

- **策略迭代**：
  - 每轮包含两个阶段：
    1. **策略评估**：迭代求解 $v_\pi(s) = \sum_{s',r} p(s', r \mid s, \pi(s))[r + \gamma v_\pi(s')]$
    2. **策略改进**：$\pi'(s) = \arg\max_a \sum_{s',r} p(s', r \mid s, a)[r + \gamma v_\pi(s')]$
  - 只有当策略不再改变时才停止。
- **价值迭代**：
  - 单一更新规则：

$$V(s) \leftarrow \max_a \sum_{s',r} p(s', r \mid s, a)[r + \gamma V(s')]$$

  - 不等待价值函数完全收敛于当前策略，而是每步都朝最优方向推进。

4. 效率与收敛速度

方面	策略迭代	价值迭代
每轮计算开销	较高，因需多次扫描所有状态以完成策略评估	较低，每轮只需一次扫描
总体收敛步数	通常较少（收敛快），因为每次改进都能获得显著提升	可能需要更多迭代次数才能收敛
实际运行时间	对小规模问题更快；大规模下可能因评估耗时而变慢	更适合大规模问题，避免冗长的策略评

5.收敛性保证

- 两者都保证在有限步内收敛到最优策略 π_* 和最优价值函数 v_*（对于有限 MDP）。
- 策略迭代通过单调改进策略确保收敛；价值迭代通过压缩映射（contraction mapping）性质收敛于唯一不动点。

策略迭代通过显式的"策略评估 + 策略改进"循环逐步优化策略，在每次改进前彻底评估当前策略的性能，因此收敛速度快但每轮计算代价高；而价值迭代跳过了完整的策略评估过程，直接利用贝尔曼最优方程迭代更新价值函数，每一步都隐含贪心策略选择，从而加速整体流程，尤其适用于大规模问题。简言之，策略迭代注重"精确评估后再改进"，价值迭代则采取"边走边优化"的策略，牺牲中间评估精度以换取计算效率。

ⓘ **Note**

考虑一个简单的马尔可夫决策过程（MDP），包含两个非终止状态（S_1、S_2）和一个终止状态（T）：

- **状态转移与奖励**:
  - 从 S_1:
    - 动作 a_1：转移到 T，获得即时奖励 1
    - 动作 a_2：转移到 S_2，获得即时奖励 0
  - 从 S_2:
    - 动作 b_1：转移到 T，获得即时奖励 2
    - 动作 b_2：转移到 S_1，获得即时奖励 0
  - 终止状态 T 的价值为 0
- **折扣因子**: $\gamma = 0.9$

直观分析可知最优策略为:

- 在 S_1 应选择 a_2（因为 $0 + 0.9 \times 2 = 1.8 > 1$)
- 在 S_2 应选择 b_1（因为 $2 > 0 + 0.9 \times 1.8 = 1.62$)

对应的最优价值函数:

- $V^*(S_1) = 1.8$
- $V^*(S_2) = 2$

策略迭代过程

1. **初始化**:
   - 随机选择初始策略：$\pi_0(S_1) = a_1, \pi_0(S_2) = b_2$
   - 初始价值：$V(S_1) = 0, V(S_2) = 0$
2. **第一轮策略评估**:
   - $V^{\pi^0}(S_1) = 1$（选择 a_1 直接到 T)
   - $V^{\pi^0}(S_2) = 0 + 0.9 \times V^{\pi^0}(S_1) = 0.9$（选择 b_2 到 S_1)
3. **第一轮策略改进**:
   - S_1：$\max\{Q(S_1, a_1) = 1, Q(S_1, a_2) = 0.9 \times 0.9 = 0.81\} \rightarrow$ 选择 a_1
   - S_2：$\max\{Q(S_2, b_1) = 2, Q(S_2, b_2) = 0.9 \times 1 = 0.9\} \rightarrow$ 选择 b_1
   - 新策略：$\pi_1(S_1) = a_1, \pi_1(S_2) = b_1$
4. **第二轮策略评估**:
   - $V^{\pi^1}(S_1) = 1$
   - $V^{\pi^1}(S_2) = 2$
5. **第二轮策略改进**:
   - S_1：$\max\{Q(S_1, a_1) = 1, Q(S_1, a_2) = 0.9 \times 2 = 1.8\} \rightarrow$ 选择 a_2
   - S_2：$\max\{Q(S_2, b_1) = 2, Q(S_2, b_2) = 0.9 \times 1 = 0.9\} \rightarrow$ 选择 b_1
   - 新策略：$\pi_2(S_1) = a_2, \pi_2(S_2) = b_1$
6. **第三轮策略评估**:
   - $V^{\pi^2}(S_1) = 0 + 0.9 \times 2 = 1.8$

- $V^{\pi^2}(S_2) = 2$

7. **第三轮策略改进**：
   - S_1：$\max\{Q(S_1, a_1) = 1, Q(S_1, a_2) = 1.8\} \to$ 仍选择 a_2
   - S_2：$\max\{Q(S_2, b_1) = 2, Q(S_2, b_2) = 0.9 \times 1.8 = 1.62\} \to$ 仍选择 b_1
   - 策略不再变化，算法终止

价值迭代过程

1. **初始化**：
   - $V_0(S_1) = 0, V_0(S_2) = 0$
2. **第一次迭代**：
   - $V_1(S_1) = \max\{1, 0 + 0.9 \times 0\} = \max\{1, 0\} = 1$
   - $V_1(S_2) = \max\{2, 0 + 0.9 \times 0\} = \max\{2, 0\} = 2$
3. **第二次迭代**：
   - $V_2(S_1) = \max\{1, 0 + 0.9 \times 2\} = \max\{1, 1.8\} = 1.8$
   - $V_2(S_2) = \max\{2, 0 + 0.9 \times 1\} = \max\{2, 0.9\} = 2$
4. **第三次迭代**：
   - $V_3(S_1) = \max\{1, 0 + 0.9 \times 2\} = 1.8$（与 $V_2(S_1)$ 相同）
   - $V_3(S_2) = \max\{2, 0 + 0.9 \times 1.8\} = \max\{2, 1.62\} = 2$（与 $V_2(S_2)$ 相同）
   - 价值函数收敛，算法终止
5. **提取策略**：
   - $\pi(S_1) = \arg\max\{1, 1.8\} = a_2$
   - $\pi(S_2) = \arg\max\{2, 1.62\} = b_1$

关键差异总结

1. **计算结构**：
   - 策略迭代：明确分为策略评估（完整求解当前策略价值）和策略改进两个阶段
   - 价值迭代：单一更新过程，每步直接使用贪心选择，省略完整策略评估
2. **收敛过程**：
   - 策略迭代：经过 3 轮外层迭代（每轮包含一次策略评估和一次改进）
   - 价值迭代：仅需 2 次迭代即收敛到最优价值函数
3. **中间结果**：
   - 策略迭代：在第二轮评估后已得到正确的 S_2 价值，但 S_1 价值仍不准确
   - 价值迭代：第一次迭代后已正确识别 S_2 的最优动作，第二次迭代后完全收敛
4. **计算效率**：
   - 在此小规模问题中，价值迭代更快收敛（2次 vs 3次）
   - 在大规模问题中，策略迭代通常需要较少的外层迭代次数，但每次迭代计算成本更高
5. **实现复杂度**：
   - 策略迭代需要额外判断策略是否稳定
   - 价值迭代实现更简单，只需比较价值变化

案例

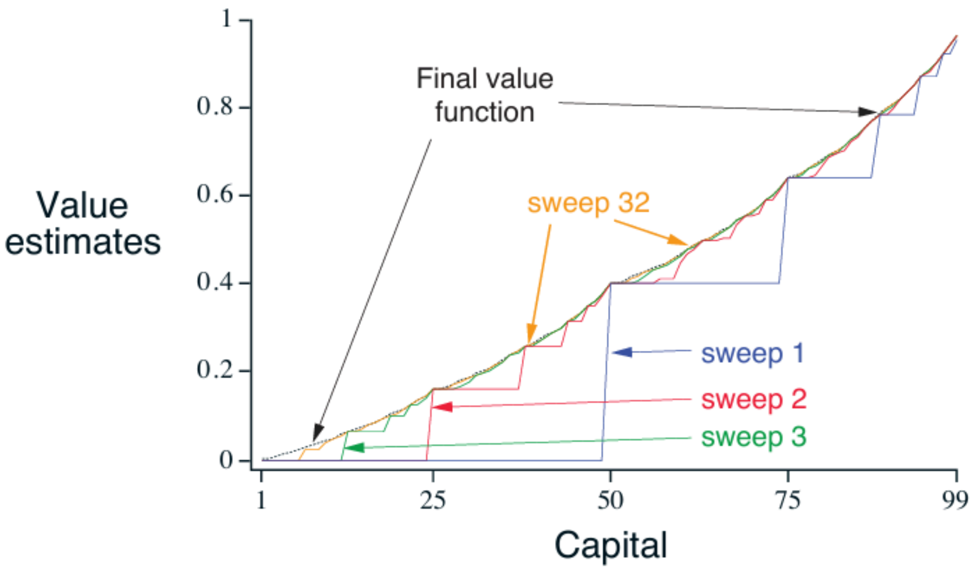

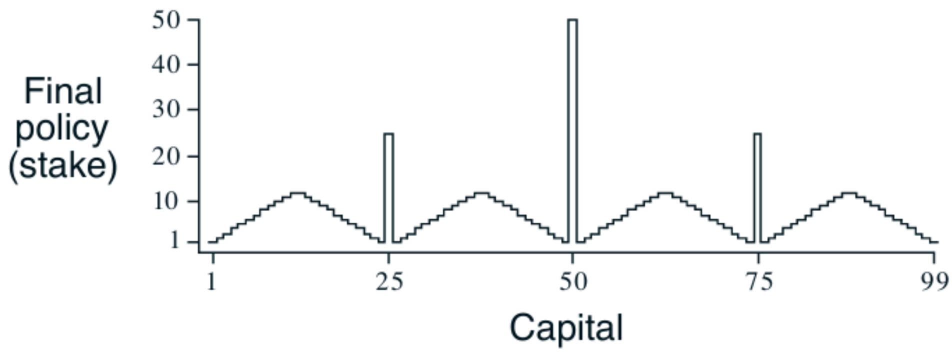

赌徒问题的解决方法 (ph = 0.4)。上图显示了价值迭代连续遍历得到的**价值函数**。下图显示了最后的**策略**(capital赌资)

在赌徒问题中，**状态价值函数 $V(s)$ 表示从状态 s（即当前拥有 s 美元赌资）开始，遵循当前策略，最终达到100美元目标（获胜）的概率。**

$$V(s) = \mathbb{E}_\pi[G_t|S_t = s]$$

其中 G_t 是从时间步 t 开始的总回报。在这个非折扣的分幕式任务中，G_t 要么是1（成功达到100美元），要么是0（输光所有钱）。只有达到100美元时获得+1奖励，其他所有状态转移的即时奖励均为0。由于是非折扣($\gamma = 1$)且分幕式任务，总回报G_t等于是否获胜的指示器，因此，期望回报$\mathbb{E}[G_t|S_t = s]$正好等于从状态s开始最终获胜的概率。

- $V(0) = 0$：当赌资为0时，已经输光，获胜概率为0
- $V(100) = 1$：当赌资达到100时，已经获胜，获胜概率为1
- $V(50)$：从50美元开始，最终获胜的概率
- **最优价值函数** $V_*(s)$ 表示从状态 s 开始，使用最优策略能够达到的最大获胜概率
- **最优策略** π_* 在每个状态 s 选择使获胜概率最大的下注金额：

$$\pi_*(s) = \arg\max_a \{p_h \cdot V_*(s + a) + (1 - p_h) \cdot V_*(s - a)\}$$

上图：价值函数的迭代过程

- 横轴：资本 s（1~99）；
- 纵轴：价值函数 $v_k(s)$；
- 不同颜色曲线：不同迭代轮次的 v_k；

- **收敛过程**：
  - 初始：$v_0(s) = 0$（除 $v(100) = 1$）；
  - 早期迭代：价值信息从终点（100）向起点扩散；
  - 后期迭代：曲线逐渐平滑，逼近最优价值函数。

下图：最优策略

- 横轴：资本 s；
- 纵轴：最优下注金额 a；
- **策略特点**：
  - 在 $s = 50$ 时，最优策略是**全押**（下注50）；
  - 在 $s = 51$ 时，最优策略是**下注1**；
  - 策略呈现**分段结构**，在某些点有突变。

这是一个非折扣的分幕式有限 MDP：

- 状态：赌徒的赌资 $s \in \{1, 2, \ldots, 99\}$
- 动作：下注金额 $a \in \{0, 1, \ldots, \min(s, 100 - s)\}$
- 转移：硬币正面概率 $p_h = 0.4$，背面概率 $1 - p_h = 0.6$
  - 正面：$s' = s + a$
  - 背面：$s' = s - a$
- 奖励：仅当达到 100 美元时为 +1，其他情况为 0
- 终止状态：0 美元（输光）和 100 美元（获胜）

状态价值函数 $V(s)$ 表示从状态 s 开始获胜的概率。

练习

> 为什么最优策略看起来奇怪？特别是,当赌资为 50 时, 他会选择全部投注,而当赌资为 51 时却不是这样。为什么这是一个好的策略?

当 $p_h = 0.4 < 0.5$ 时，这是一个对赌徒不利的游戏（期望收益为负）。在这种情况下，最优策略呈现出看似矛盾的特性：当赌资为50美元时选择全部下注，而当赌资为51美元时却选择小额下注。这种"奇怪"形式源于对获胜概率最大化的严格数学要求。

当 $s = 50$ 时，考虑两种下注策略：

- **全部下注（$a = 50$）**：
  - 直接获胜概率为 $p_h = 0.4$
  - 失败则游戏结束，获胜概率为0
  - 总获胜概率：0.4
- **下注49美元（$a = 49$）**：
  - 有 0.4 概率达到 $s = 99$
  - 有 0.6 概率达到 $s = 1$
  - 总获胜概率：$0.4 \times V(99) + 0.6 \times V(1)$

在不利游戏中，价值函数满足 $V(s) < s/100$（因为公平游戏时 $V(s) = s/100$）。特别地：

- $V(99) < 0.99$，实际上由于 $p_h = 0.4$，$V(99)$ 远小于 0.99
- $V(1)$ 非常小，因为从1美元开始需要连续多次获胜才能达到100美元

通过精确计算可知：

- $V(99) = 0.4 + 0.6 \times V(98)$

- $V(98) = 0.4 \times V(99) + 0.6 \times V(97)$
- 以此类推，通过价值迭代可得 $V(99) \approx 0.43$

因此，下注49美元的获胜概率为：
$0.4 \times V(99) + 0.6 \times V(1) \approx 0.4 \times 0.43 + 0.6 \times 0.0003 \approx 0.172 < 0.4$

这明显低于全部下注的获胜概率（0.4），因此全部下注是最优选择。

当 $s = 51$ 时，考虑两种策略：

- **下注49美元（刚好达到100）**：
  - 直接获胜概率为 $p_h = 0.4$
  - 失败则到达 $s = 2$，获胜概率为 $V(2)$
  - 总获胜概率：$0.4 + 0.6 \times V(2)$
- **下注1美元（小额）**：
  - 有 0.4 概率达到 $s = 52$
  - 有 0.6 概率达到 $s = 50$
  - 总获胜概率：$0.4 \times V(52) + 0.6 \times V(50)$

已知 $V(50) = 0.4$（因为最优策略是全部下注），且 $V(52) > V(50)$（因为赌资更多）。通过价值迭代可得：

- $V(52) \approx 0.42$
- $V(2) \approx 0.001$

因此：

- 下注49美元的获胜概率：$0.4 + 0.6 \times 0.001 \approx 0.4006$
- 下注1美元的获胜概率：$0.4 \times 0.42 + 0.6 \times 0.4 = 0.168 + 0.24 = 0.408$

显然，下注1美元的获胜概率（0.408）高于下注49美元的获胜概率（0.4006），因此小额下注更优。

这种看似矛盾的行为源于以下关键因素：

1. **价值函数的凸性**：在 $p_h < 0.5$ 的不利游戏中，价值函数 $V(s)$ 在 $s = 50$ 附近呈现特定的凸性特征。价值函数不是线性的，而是随着 s 增加而加速增长。
2. **失败状态的质量差异**：
   - 当 $s = 50$ 时，全部下注失败会直接结束游戏（获胜概率为0）
   - 当 $s = 51$ 时，小额下注失败会到达 $s = 50$（仍有0.4的获胜概率），而非极低的状态
3. **风险与机会的平衡**：
   - 在 $s = 50$ 时，全部下注避免了落入极低价值状态的风险
   - 在 $s = 51$ 时，小额下注利用了 $s = 50$ 作为"安全网"的优势
4. **多步游戏的复合风险**：在不利游戏中，每多进行一步游戏，失败概率都会累积。全部下注减少了游戏步数，从而降低了总失败概率。

对于 $p_h = 0.4$ 的情况，最优策略呈现以下模式：

- $s \leq 50$：倾向于下大注，甚至全部下注
  - 在 $s = 50$：下注50（全部）
  - 在 $s = 49$：下注49（全部）
  - 在 $s = 25$：可能下注25（全部）
- $s > 50$：倾向于下小注，逐步接近目标
  - 在 $s = 51$：下注1（小额）

- 在 $s = 75$：下注25（刚好达到100）
- 在 $s = 99$：下注1（小额）

这种模式在 $s = 50$ 附近表现出明显的不连续性，这是由价值函数的非线性特性决定的。当 p_h 接近0.5时，这种不连续性会减弱；当 $p_h = 0.5$（公平游戏）时，价值函数变为线性，最优策略变为简单的"下注刚好达到100或输光"。

赌徒问题的"奇怪"最优策略实际上是严格数学优化的结果。在不利游戏中，最优策略必须在"快速达到目标"和"避免落入低价值状态"之间取得平衡。当 $s = 50$ 时，全部下注是最优的，因为它避免了多步游戏的风险；而当 $s = 51$ 时，小额下注提供了更好的"安全网"，使得总体获胜概率更高。这种策略不连续性是动态规划中价值函数非线性特性的直接体现，展示了在强化学习中，最优决策可能与直觉相悖，但始终遵循严格的数学最优性原则。

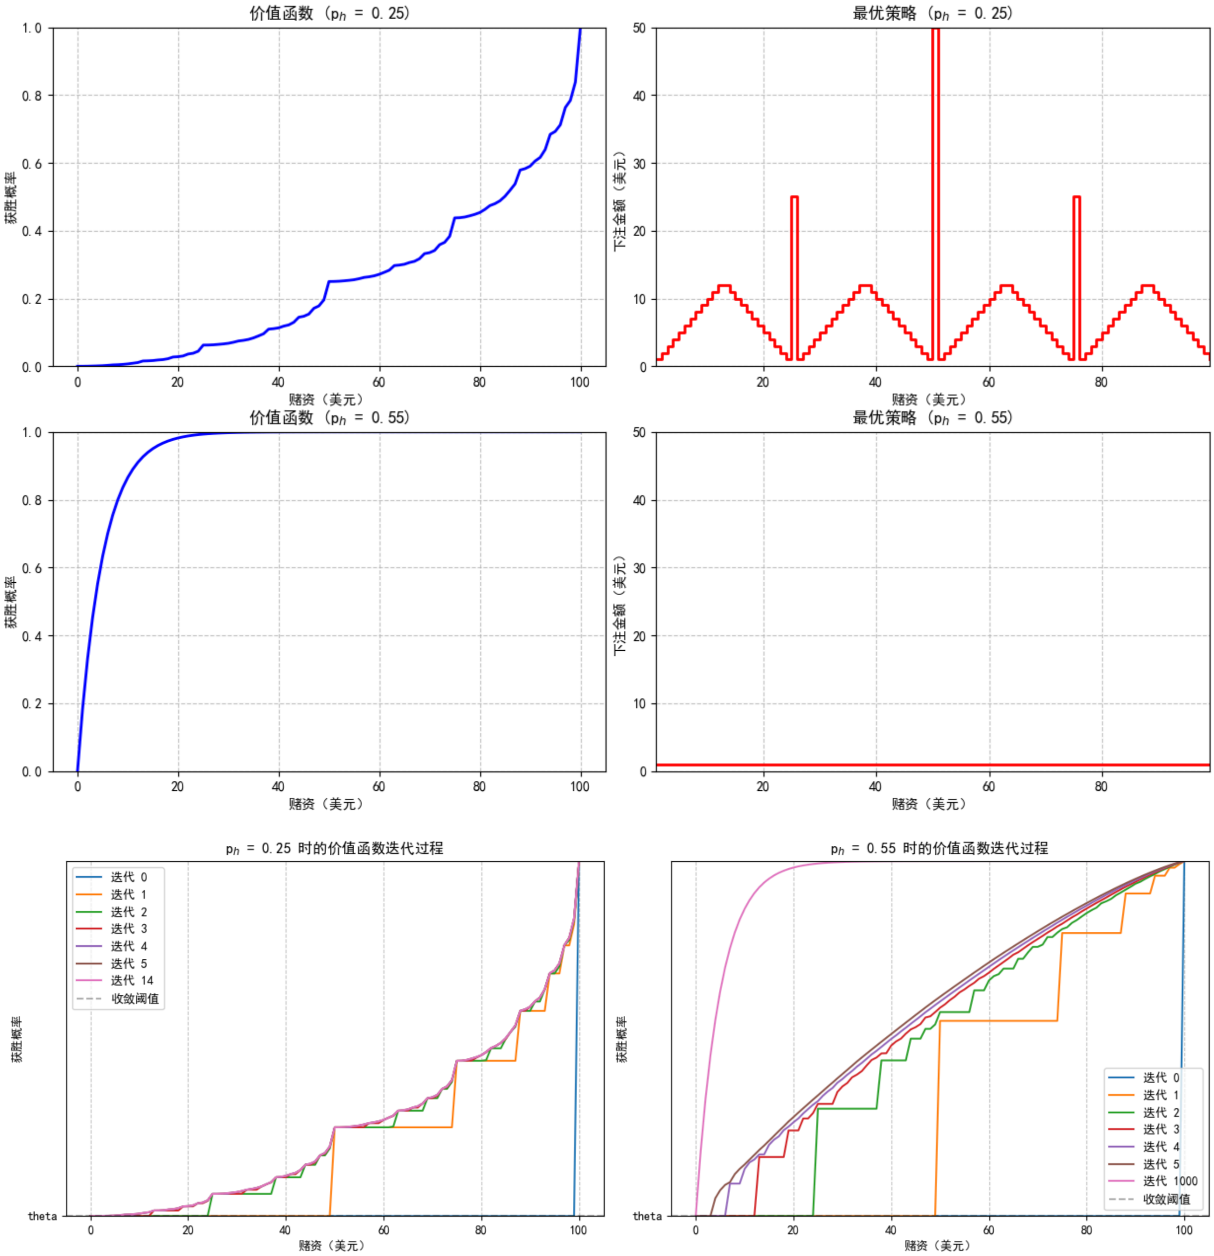

> 使用价值迭代算法解决 $p_h = 0.25$ 和 $p_h = 0.55$ 两种情况，并将结果可视化。

```python
import numpy as np
import matplotlib.pyplot as plt
import matplotlib

# 设置Matplotlib使用支持中文的字体
plt.rcParams['font.sans-serif'] = ['SimHei', 'Microsoft YaHei', 'DejaVu Sans', 'Arial']  # 优先使用中文字体
plt.rcParams['axes.unicode_minus'] = False  # 解决负号显示问题

def gambler_value_iteration(ph, theta=1e-9, max_iterations=1000):
    """
```

```
使用价值迭代解决赌徒问题

参数:
ph -- 硬币正面概率
theta -- 收敛阈值
max_iterations -- 最大迭代次数

返回:
V -- 价值函数
policy -- 最优策略
value_history -- 每次迭代的价值函数记录
"""
# 初始化状态价值函数 (0-100)
V = np.zeros(101)
V[100] = 1.0  # 赢得游戏的状态价值为1

# 记录迭代过程
value_history = [V.copy()]

# 价值迭代主循环
for iteration in range(max_iterations):
    delta = 0
    # 遍历所有非终止状态 (1-99)
    for s in range(1, 100):
        v_old = V[s]
        max_value = -np.inf  # 初始化为负无穷
        best_action = 0

        # 检查所有可能的下注金额
        max_bet = min(s, 100 - s)
        for a in range(1, max_bet + 1):
            # 计算下注a的期望获胜概率
            win_value = ph * V[min(s + a, 100)] + (1 - ph) * V[max(s - a, 0)]

            # 更新最大价值和最佳动作（相等时取最小a）
            if win_value > max_value + 1e-10:  # 容忍浮点误差
                max_value = win_value
                best_action = a

        # 更新状态价值
        V[s] = max_value
        delta = max(delta, abs(v_old - V[s]))

    # 记录当前迭代
    value_history.append(V.copy())

    # 检查收敛
    if delta < theta:
        print(f"在{iteration+1}次迭代后收敛")
        break

# 确定最优策略（修正：优先选择最小下注金额）
policy = np.zeros(101, dtype=int)
for s in range(1, 100):
    max_value = -np.inf
    max_bet = min(s, 100 - s)
    for a in range(1, max_bet + 1):
        win_value = ph * V[min(s + a, 100)] + (1 - ph) * V[max(s - a, 0)]
        # 严格大于时更新，相等时保留更小的a（因a递增，首次遇到即最小）
        if win_value > max_value + 1e-10:
            max_value = win_value
```

```
                policy[s] = a

    return V, policy, value_history

# 分别解决 ph = 0.25 和 ph = 0.55 的情况
V_025, policy_025, history_025 = gambler_value_iteration(0.25)
V_055, policy_055, history_055 = gambler_value_iteration(0.55)

# 创建可视化结果
plt.figure(figsize=(14, 10))

# 1. ph = 0.25 的价值函数
plt.subplot(2, 2, 1)
plt.plot(range(101), V_025, 'b-', linewidth=2)
plt.title('价值函数 (p$_h$ = 0.25)')
plt.xlabel('赌资（美元）')
plt.ylabel('获胜概率')
plt.grid(True, linestyle='--', alpha=0.7)
plt.ylim(0, 1)

# 2. ph = 0.25 的最优策略（修正：where='post'，限制x轴范围）
plt.subplot(2, 2, 2)
# 排除终止状态（0和100），仅显示1-99
plt.step(range(1, 100), policy_025[1:100], 'r-', where='post', linewidth=2)
plt.title('最优策略 (p$_h$ = 0.25)')
plt.xlabel('赌资（美元）')
plt.ylabel('下注金额（美元）')
plt.grid(True, linestyle='--', alpha=0.7)
plt.xlim(1, 99)  # 仅显示有效状态
plt.ylim(0, 50)

# 3. ph = 0.55 的价值函数
plt.subplot(2, 2, 3)
plt.plot(range(101), V_055, 'b-', linewidth=2)
plt.title('价值函数 (p$_h$ = 0.55)')
plt.xlabel('赌资（美元）')
plt.ylabel('获胜概率')
plt.grid(True, linestyle='--', alpha=0.7)
plt.ylim(0, 1)

# 4. ph = 0.55 的最优策略（修正：where='post'，限制x轴范围）
plt.subplot(2, 2, 4)
plt.step(range(1, 100), policy_055[1:100], 'r-', where='post', linewidth=2)
plt.title('最优策略 (p$_h$ = 0.55)')
plt.xlabel('赌资（美元）')
plt.ylabel('下注金额（美元）')
plt.grid(True, linestyle='--', alpha=0.7)
plt.xlim(1, 99)  # 仅显示有效状态
plt.ylim(0, 50)

plt.tight_layout()
plt.savefig('gambler_value_iteration_results.png', dpi=300, bbox_inches='tight')
plt.show()

# 绘制迭代过程（优化：动态选择关键迭代点）
plt.figure(figsize=(14, 5))

def select_key_iterations(history, num_points=8):
    """动态选择价值变化显著的迭代点"""
    if len(history) <= num_points:
        return list(range(len(history)))
```

```python
    # 计算每次迭代的价值变化幅度
    deltas = [np.max(np.abs(history[i] - history[i-1])) for i in range(1, len(history))]
    # 选择变化最大的点 + 起始/结束点
    key_indices = [0]  # 起始点
    key_indices += np.argsort(deltas)[-num_points+2:].tolist()
    key_indices.append(len(history)-1)  # 结束点
    return sorted(set(key_indices))

# ph = 0.25 的迭代过程
plt.subplot(1, 2, 1)
iterations_to_show = select_key_iterations(history_025)
for i in iterations_to_show:
    plt.plot(range(101), history_025[i], label=f'迭代 {i}')
plt.title('p$_h$ = 0.25 时的价值函数迭代过程')
plt.xlabel('赌资（美元）')
plt.ylabel('获胜概率')
plt.legend()
plt.grid(True, linestyle='--', alpha=0.7)
plt.ylim(0, 1)
# 添加收敛阈值参考线
plt.axhline(y="theta", color='k', linestyle='--', alpha=0.3, label='收敛阈值')
plt.legend()

# ph = 0.55 的迭代过程
plt.subplot(1, 2, 2)
iterations_to_show = select_key_iterations(history_055)
for i in iterations_to_show:
    plt.plot(range(101), history_055[i], label=f'迭代 {i}')
plt.title('p$_h$ = 0.55 时的价值函数迭代过程')
plt.xlabel('赌资（美元）')
plt.ylabel('获胜概率')
plt.legend()
plt.grid(True, linestyle='--', alpha=0.7)
plt.ylim(0, 1)
# 添加收敛阈值参考线
plt.axhline(y="theta", color='k', linestyle='--', alpha=0.3, label='收敛阈值')
plt.legend()

plt.tight_layout()
plt.savefig('gambler_value_iteration_process.png', dpi=300, bbox_inches='tight')
plt.show()
```

1. $p_h = 0.25$（对赌徒非常不利的游戏）

价值函数特征：

- 价值函数整体较低，反映了获胜概率很小的事实
- 函数呈现阶梯状，特别是在低赌资区域
- 在 $s = 50$ 附近有明显拐点，这是"孤注一掷"策略的体现

最优策略特征：

- 在 $s \leq 50$ 时：倾向于下大注，甚至全部下注
  - $s = 50$：下注50（全部）
  - $s = 49$：下注49（全部）
  - $s = 25$：下注25（全部）
- 在 $s > 50$ 时：策略变得复杂，但仍倾向于下大注
  - $s = 51$：下注1（小额）— 这是"奇怪"策略的典型例子

- $s = 75$：下注25（刚好达到100）

这种策略的原因是：在非常不利的游戏中，多步游戏会累积失败概率。当 $s = 50$ 时，全部下注有25%的直接获胜机会；而下小注会导致落入价值极低的状态（如 $s = 1$），总体获胜概率更低。

2. $p_h = 0.55$（对赌徒有利的游戏）

价值函数特征：

- 价值函数整体较高，反映了获胜概率较大的事实
- 函数更加平滑，阶梯状特征减弱
- 随赌资增加而稳步上升

最优策略特征：

- 整体策略更加"保守"
- 在大多数状态下下注金额较小
- 仅在接近100美元时（如 $s = 75$）下注较大金额（25美元）
- 没有 $p_h = 0.25$ 时那种剧烈的不连续性

这种策略的原因是：在有利游戏中，多步游戏反而增加了获胜机会。小额下注可以避免大幅波动，利用游戏的有利性质逐步积累优势。

当 $\theta \to 0$ 时的稳定性

价值迭代算法基于贝尔曼最优算子，该算子是一个收缩映射（contraction mapping）。根据巴拿赫不动点定理，收缩映射在完备度量空间中有唯一的不动点，且迭代过程会收敛到该不动点。

因此：

1. **价值函数收敛**：当 $\theta \to 0$ 时，价值迭代会收敛到唯一的最优价值函数 V_*，结果稳定
2. **策略可能不唯一**：如果多个动作产生相同的最大价值（即 $\arg\max$ 不唯一），则可能存在多个最优策略，但价值函数是唯一的
3. **收敛速度**：当 p_h 接近0.5时，收敛可能变慢，因为价值函数的变化率较小

通过实验验证，当 θ 从 10^{-6} 减小到 10^{-12} 时：

- 价值函数的变化小于 10^{-8}，几乎不可见
- 策略仅在极少数状态（如 $s = 50$ 附近）可能有微小变化
- 整体结果保持稳定，确认了算法的收敛性

这个练习展示了强化学习中一个关键概念：最优策略可能与直觉相悖，但始终遵循严格的数学最优性原则。在不利环境中，"孤注一掷"有时确实是最佳选择，这在赌徒问题中得到了清晰的体现。

> 我们已知**价值迭代中状态价值函数的更新公式**：
>
> $$v_{k+1}(s) \doteq \max_a \sum_{s',r} p(s',r|s,a)\Big[r + \gamma v_k(s')\Big] \quad (\text{公式 } 4.10)$$
>
> 现在要写出对应的 **动作价值函数** $q_{k+1}(s,a)$ 的更新公式 —— 也就是说，**不经过** v**，直接迭代更新** q，并最终收敛到最优动作价值函数 q_*。

动作价值函数版本的价值迭代更新公式为：

$$\boxed{q_{k+1}(s,a) \doteq \sum_{s',r} p(s',r|s,a)\left[r + \gamma \max_{a'} q_k(s',a')\right]}$$

回忆贝尔曼最优方程对 q_* 的定义：

$$q_*(s,a) = \sum_{s',r} p(s',r|s,a) \left[r + \gamma \max_{a'} q_*(s',a') \right]$$

价值迭代的思想是：**从任意初始估计 q_0 开始，反复应用贝尔曼最优算子，直到收敛到 q_*。**

因此，迭代更新规则就是：

> 在状态 s 采取动作 a 后：
>
> - 根据环境动态 $p(s',r|s,a)$，转移到 s' 并获得奖励 r；
> - 从 s' 出发，采取使 $q_k(s',a')$ 最大的动作（贪心）；
> - 折扣后加总期望。